

Instituto Politécnico Nacional
Escuela Superior de Cómputo



Trabajo Terminal: 2026-A114

Simulación de sistemas complejos mediante autómatas celulares neuronales

---

Presenta:

Angeles Lopez Erick Jesse

eangelesl1700@alumno.ipn.mx

Director:

Dr. Genaro Juárez Martínez

Ciudad de México, 8 de octubre de 2026

Índice general

1. Experimentación y resultados **1**

1.1. Replicación de comportamientos conocidos 2

1.1.1. Duplicación de reglas del juego de la vida 2

1.1.1.1. Efecto del tamaño de la vecindad 12

1.1.2. Incremento de vecindad 20

1.1.3. Sandpile 29

1.1.4. Hormiga de Langton 31

1.2. Replicación de sistemas complejos naturales 33

1.2.1. Propagación de un incendio (FLAME 3) 33

1.2.1.1. Datos de origen 33

1.2.1.2. Limpieza 34

1.2.1.3. Entrenamiento y resultados 36

1.2.2. Desarrollo embrionario 37

1.2.2.1. Datos de origen 37

1.2.2.2. Limpieza 37

1.2.2.3. Entrenamiento y resultados 40

1.2.3. Seguimiento de células (Cell Tracking Challenge) 41

1.3. Morfogénesis 41

Referencias **42**

Capítulo 1

Experimentación y resultados

Una vez construido, validado e implementado el simulador, es momento de la experimentación y del análisis de resultados. A lo largo de este capítulo se exponen los tres experimentos realizados con el simulador para entrenar autómatas celulares neuronales y analizar en Mathematica las evoluciones que generan. Los experimentos avanzan de sistemas con una regla conocida hacia sistemas de los que solo se conoce su resultado:

1. **Replicación de comportamientos conocidos** (sección 1.1). Se entrena el autómata celular neuronal con evoluciones de reglas bien conocidas (juego de la vida, *sandpile* y hormiga de Langton) para medir su capacidad de recuperar la regla a partir de la evolución y la vecindad.

2. **Replicación de sistemas complejos naturales** (sección 1.2). Se entrena con evoluciones obtenidas de sistemas reales sin una regla de transición conocida: la propagación de un incendio, el desarrollo de un embrión y el movimiento de células en cultivo. Cada sistema requiere su propio método de limpieza para llevar los datos al formato (T, n, n) del simulador.

3. **Morfogénesis** (sección 1.3). Se conoce la condición inicial y la configuración final, pero no la evolución intermedia; el autómata debe encontrar una regla que lleve de una a otra.

1.1. Replicación de comportamientos conocidos

El objetivo de este experimento es replicar evoluciones de reglas conocidas para identificar la capacidad del autómata celular neuronal de reproducir un comportamiento a partir de su evolución y su vecindad. Al conocerse la regla original, es posible comparar directamente la regla aprendida contra la de referencia.

1.1.1. Duplicación de reglas del juego de la vida

El objetivo de este primer experimento es replicar el comportamiento de evoluciones conocidas para identificar la capacidad del autómata celular neuronal de replicar comportamientos con base en su evolución y su vecindad.

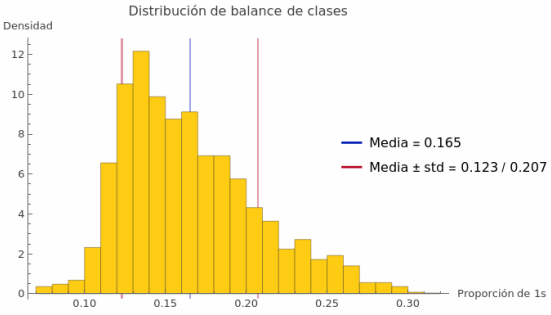
Cada regla es un problema diferente. Por lo tanto, la generación de datos es única por configuración, es por esto que las siguientes pruebas están enfocadas únicamente en la regla B3/S23.

El entrenamiento de la red neuronal requiere una ingesta de datos balanceados, para realizar las mediciones, fueron evolucionadas 100 condiciones iniciales aleatorias en un espacio de 100×100 durante 100 pasos evolutivos.

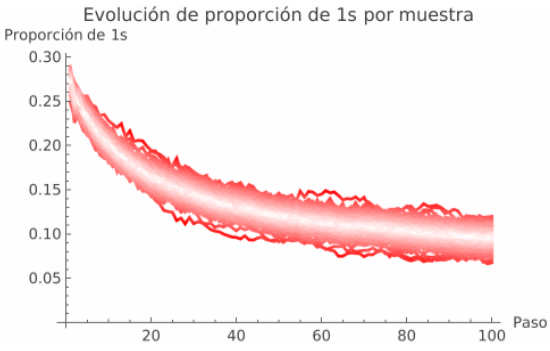
De acuerdo con la figura 1.1a, la regla B3/S23 produce el estado 1 un 16.5 % de las veces. Teniendo en cuenta la desviación estándar, concluimos que en la mayoría de los escenarios este porcentaje se encuentra entre 12.3 % y 20.7 % del total de los datos, un desbalanceo moderado-bajo que resulta manejable por la red neuronal. La mayoría de los valores mayores a estos porcentajes son obtenidos por las condiciones iniciales que inician en un 50 %. Esto se demuestra en la figura 1.1b donde la proporción del estado 1 de todas las evoluciones a través del tiempo decrece hasta estabilizarse, comportamiento característico del atractor de dicha regla.

Adicionalmente, dado que la salida de cada paso evolutivo es la entrada del siguiente, también se analiza el desbalanceo de entradas, es decir, la frecuencia con la que diferentes patrones aparecen. Para esto, utilizaremos la nomenclatura $CxNy$ para contar el número de unos que aparecen en el centro (C) y en el exterior (N).

En la figura 1.2 se muestran las frecuencias de aparición de todos los patrones en el mismo conjunto de datos. Se observa el desbalanceo y una propiedad de la regla B3/S23 de no generar mucha vida dentro de las comunidades. Los patrones con



(a) Histograma de distribución de la clase 1. Media de 16.5 y desviación estándar de 4.2.



(b) Proporción de unos a lo largo del tiempo de todas las muestras.

Figura 1.1: Resultados estadísticos del conjunto de pruebas para la regla B3/S23.

menor frecuencia de aparición son $C1N8$ y $C0N8$ sumando menos del 0.02 % del total de patrones, lo que causa un problema de representación o sesgo de muestra.

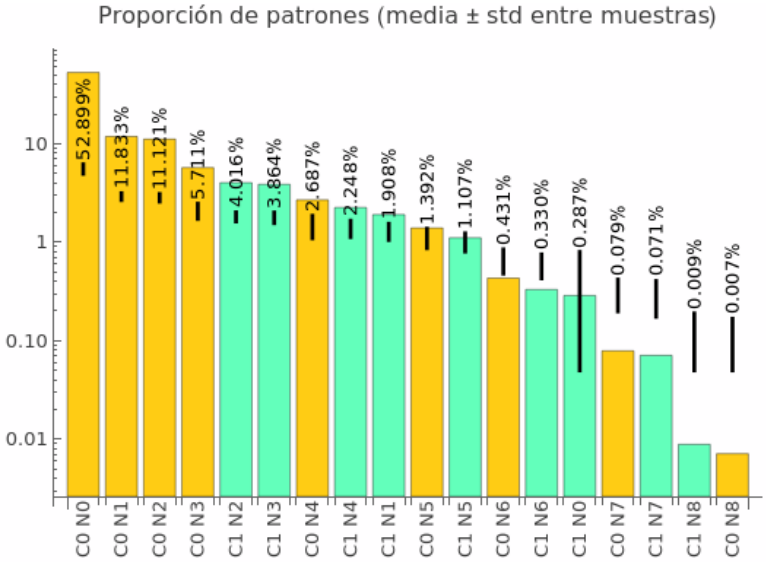


Figura 1.2: Distribuciones de probabilidad de los patrones en la regla B3/S23.

Para combatir esto, existen dos soluciones: (1) realizar un sobremuestreo de los datos menos frecuentes o (2) modificar la función de costo para penalizar en mayor medida los errores en patrones poco representados. Las próximas pruebas buscan disminuir la perdida objetivo con la intención de encontrar configuraciones capaces de replicar el comportamiento de forma exacta.

Considerando una red neuronal de 9 neuronas en la capa de entrada, se probaron 10 combinaciones de funciones de activación, de las cuales una sola converge en menos de 1000 épocas, tal como se observa en la tabla 1.1. La falta de convergencia puede deberse al tamaño de la red neuronal o la pérdida objetivo utilizada.

Capa Oculta	**Capa Salida**	**Épocas**	**Pérdida**	**Tiempo**
1:4:ReLU	2:Linear	122	0.000098	4.64 s
1:4:TanH	1:Sigmoid	1000	0.052895	40.19 s
1:4:TanH	2:Linear	1000	0.079425	36.52 s
1:4:Sigmoid	2:Linear	1000	0.159343	36.71 s
1:4:Sigmoid	1:Sigmoid	1000	0.159343	39.37 s
1:4:ReLU	2:TanH	1000	0.179589	38.65 s
1:4:ReLU	1:Sigmoid	1000	0.269196	38.16 s
1:4:Linear	1:Sigmoid	1000	0.297529	39.12 s
1:4:Linear	2:Linear	1000	0.297529	34.75 s
1:4:ReLU	2:Sigmoid	1000	0.374756	37.55 s

Tabla 1.1: Comparativa de rendimiento con múltiples hiperparámetros de la regla B3/S23: Pérdida objetivo 0.0001, límite de épocas: 1000, tamaño del lote: 8192, tasa de aprendizaje: 0.001, semilla aleatoria: 42.

Si incrementamos el número de capas ocultas y de neuronas, se observa en la tabla 1.2 que existen cinco configuraciones que alcanzan la convergencia. Adicionalmente, en la figura 1.3 observamos que el estancamiento ocurre en las primeras 12 épocas, lo que sugiere una limitación de la tasa de aprendizaje.

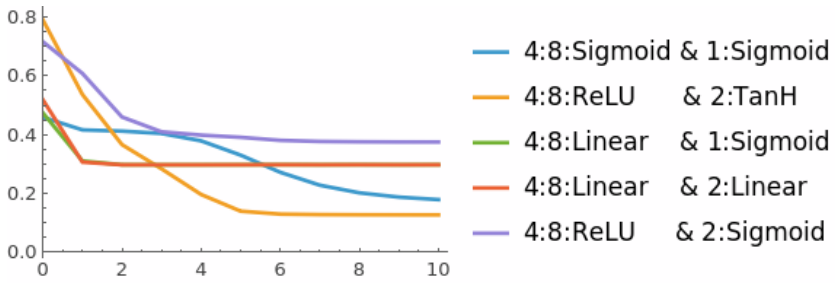


Figura 1.3: Registro de pérdida obtenida en los primeros 12 pasos de las configuraciones sin convergencia de la tabla 1.2.

Al haber encontrado configuraciones de la red neuronal que son capaces de converger con una pérdida de 0.0001. Queda demostrado que un autómata celular

Capa Oculta	**Capa Salida**	**Épocas**	**Pérdida**
4:8:ReLU	2:Linear	18	0.000087
4:8:TanH	1:Sigmoid	51	0.000097
4:8:TanH	2:Linear	35	0.000097
4:8:Sigmoid	2:Linear	79	0.000095
4:8:Sigmoid	1:Sigmoid	1000	0.159342
4:8:ReLU	2:TanH	1000	0.126928
4:8:ReLU	1:Sigmoid	133	0.000096
4:8:Linear	1:Sigmoid	1000	0.297542
4:8:Linear	2:Linear	1000	0.297544
4:8:ReLU	2:Sigmoid	1000	0.374756

Tabla 1.2: Comparativa de rendimiento con múltiples hiperparámetros de la regla B3/S23: Pérdida objetivo 0.0001, límite de épocas: 1000, tamaño del lote: 8192, tasa de aprendizaje: 0.001, semilla aleatoria: 42.

neuronal puede aprender el comportamiento de una regla ya conocida con un error mínimo. Para el objetivo de esta investigación, resulta innecesario experimentar con el resto de configuraciones no convergentes; las configuraciones descubiertas serán utilizadas para los próximos experimentos.

De acuerdo con la figura 1.2, la probabilidad de aparición de los patrones $C0N8$ y $C1N8$ son casi imperceptibles (menos del 0.02 %). Con las siguientes pruebas se busca identificar cómo afecta la variación de la pérdida objetivo con la regla aprendida. Para esto, entrenaremos la regla B3/S23 con diferentes perdidas objetivo e identificaremos si dicha probabilidad de aparición afecta en el aprendizaje.

Aunque las reglas del juego de la vida son semitotalísticas, cabe la posibilidad de que la regla aprendida no lo sea, es decir, el autómata celular neuronal puede hacer distinción entre dos patrones que tengan la misma forma. Por ejemplo, podemos generar de 8 formas diferentes el patrón $C0N1$:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \cdots = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

pero a falta de exposición de todas las posibles configuraciones, es posible que la red neuronal marque una distinción en uno o varios de esos elementos, convirtiendo a la regla en una tradicional.

Como se mencionó en el capítulo **??**, las reglas tradicionales y las semitotalísticas son subconjuntos mutuos. Para verificar que la regla aprendida coincida con

todas las posibles configuraciones de los patrones, se diseñó el espacio de la figura 1.4, se evoluciona un paso y se comparan los centros de cada permutación.

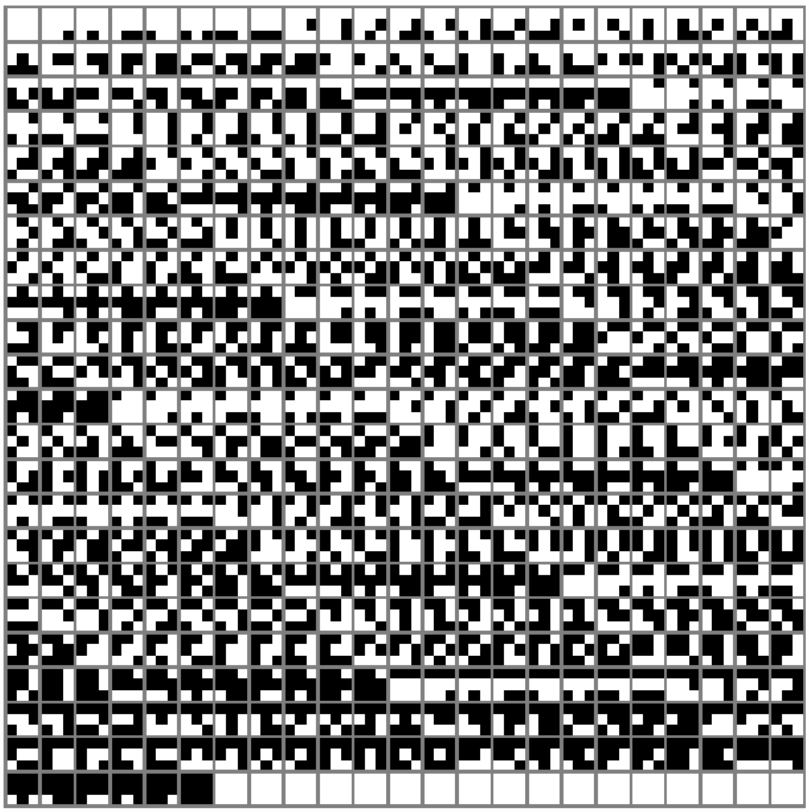


Figura 1.4: Espacio que contiene todas las permutaciones posibles de 2 estados en 9 células.

De acuerdo con la figura 1.5, la pérdida objetivo de la regla B3/S23 tiene que ser menor o igual a 0.1.

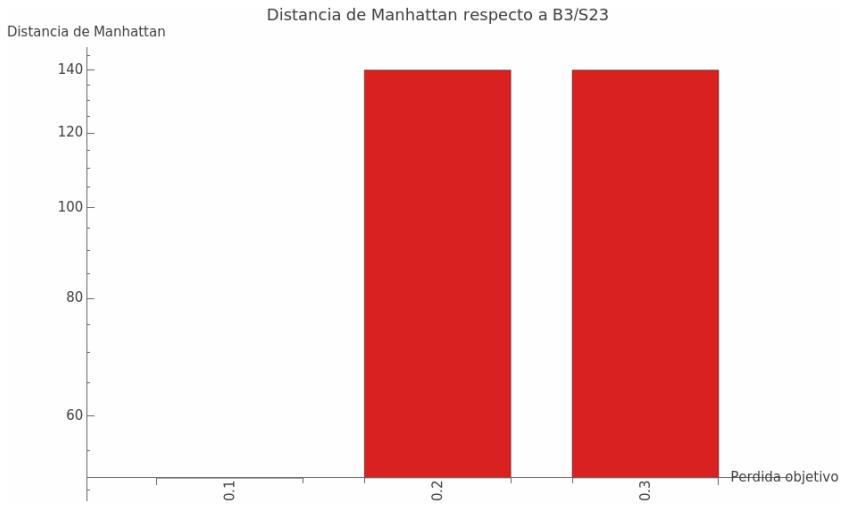


Figura 1.5: Distancia Manhattan de los vectores de regla de múltiples perdidas objetivo comparadas con B3/S23.

Los autómatas celulares neuronales que utilizaron la pérdida objetivo de 0.2 y 0.3 aprendieron la regla 0, es decir, todas las configuraciones evolucionan a 0. Podemos suponer que esta configuración es estable porque, aunque existan patrones de baja frecuencia como $C0N8$ y $C1N8$, sigue siendo capaz de replicar el comportamiento con una pérdida objetivo de 0.1. Una hipótesis es que la red neuronal se inicializa para generar ceros, al no recibir nunca esas entradas, se mantienen en 0.

Al entrenar con la regla B3/S23 el autómata celular neuronal no aprende ningún otro comportamiento. A continuación se muestra la comparativa de las pérdidas objetivo de las reglas B3/S238 (Figura 1.6) B38/S23 (1.7), B3/S238 (1.8) y B38/S238 (1.9).

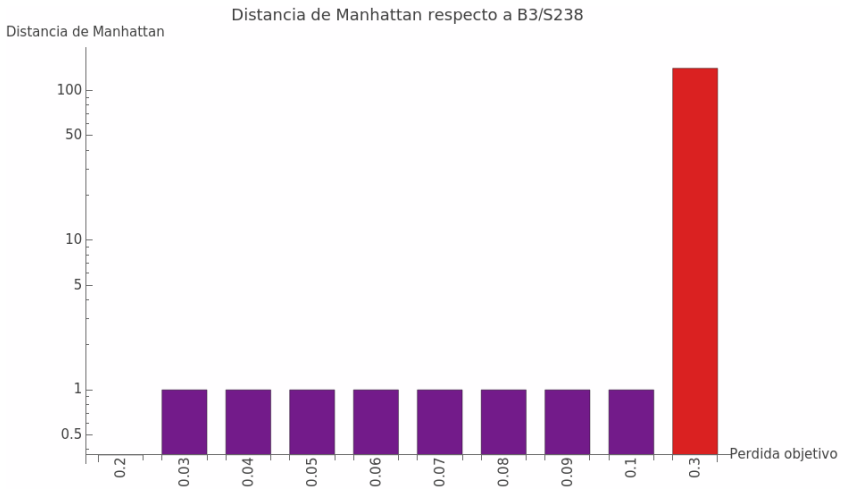


Figura 1.6: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B3/S238.

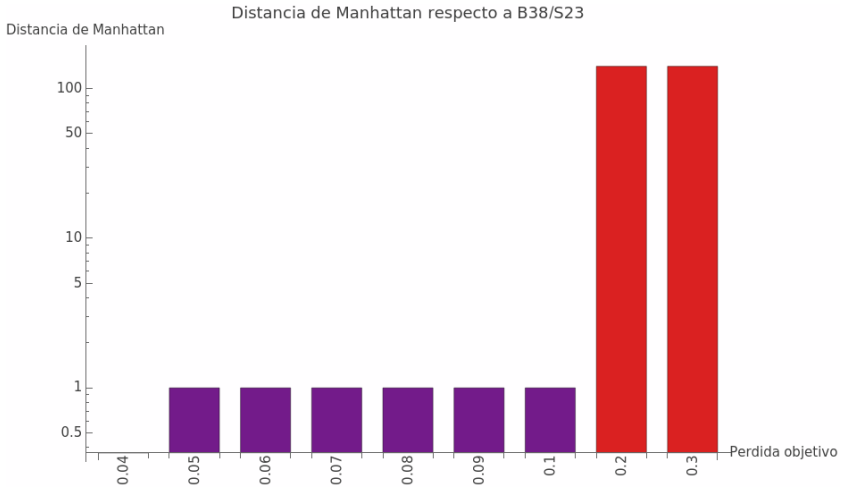


Figura 1.7: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B38/S23.

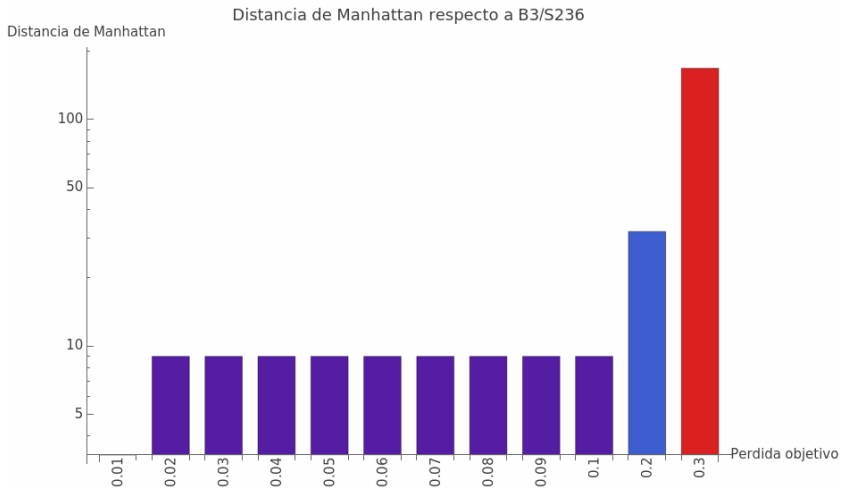


Figura 1.8: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B3/S236.

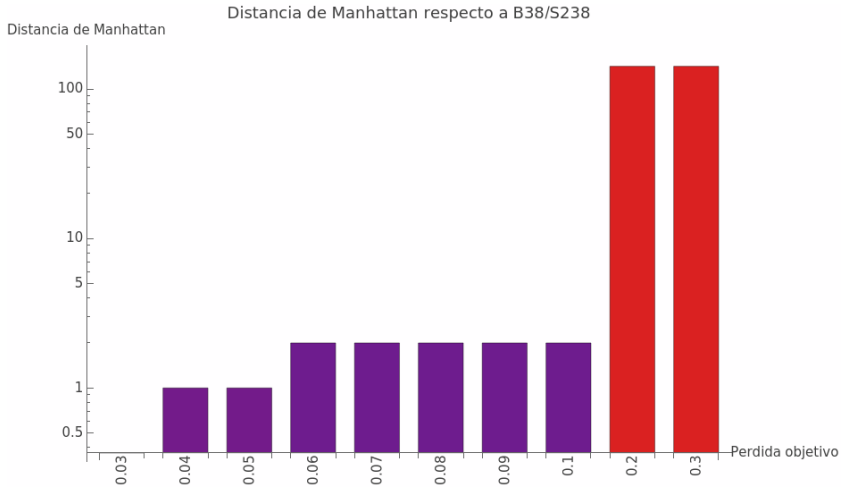


Figura 1.9: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B38/S238.

La regla B3/S238 suele aprender otra regla que difiere únicamente en un elemento. Esta única diferencia pertenece al patrón $C1N8$ el cual solo tiene una posible representación:

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

es decir, no considera la supervivencia con 8 vecinos, por lo que su regla aprendida es B3/S23. Esto lo corroboramos con la figura 1.10, en donde se muestra la única diferencia entre ambas reglas y cómo fue omitida durante el entrenamiento. Este mismo fenómeno ocurre en la regla B38/S238.



Figura 1.10: Últimos 50 elementos de los vectores de regla de B3/S238, B3/S23 y los aprendidos por el autómata celular neuronal.

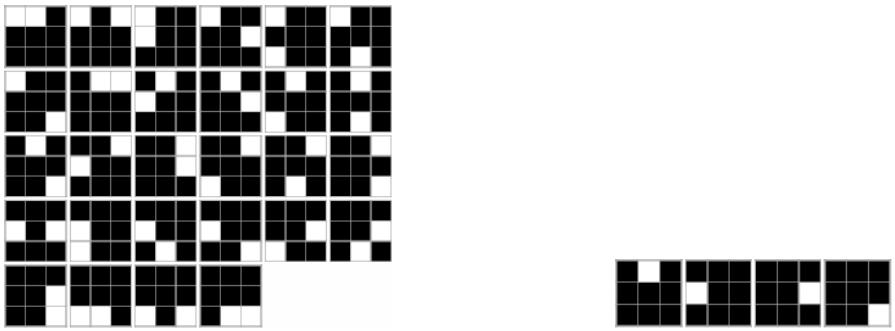
Para la regla B38/S238 se aprendieron 2 comportamientos diferentes, la regla B3/S238 y B3/S23, como se observa en la figura 1.11.



Figura 1.11: Últimos 50 elementos de los vectores de regla de B38/S238, B3/S23, B3/S238 y los aprendidos por el autómata celular neuronal.

En la regla B3/S236 existe un comportamiento diferente. Por un lado, con la pérdida objetivo de 0.2 difiere en 32 elementos. 28 de ellos (figura 1.12a) aprendió un 0 en lugar de 1, todos estos patrones corresponden a $C1N6$, por lo que si fuera solo por estas diferencias, hubiera aprendido la regla B3/S23. Sin embargo, también tuvo diferencias en 4 patrones más, donde intercambió el 1 por el 0 (figura

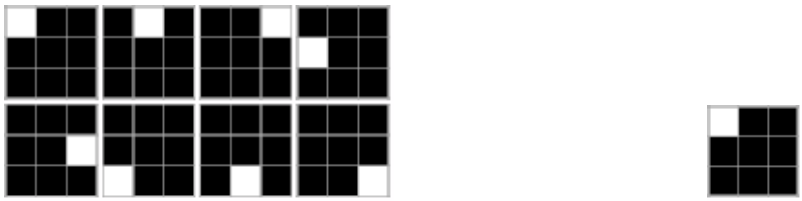
1.12b). Sin embargo, nótese que, aunque esos 4 patrones pertenecen a $C1N7$, faltan combinaciones. Por esta razón, la regla aprendida no es semitotalística, porque hace distinción de los elementos de su vecindad.



(a) Se intercambió 1 por 0 en $C1N6$ (b) Se intercambió 0 por 1.

Figura 1.12: Patrones que difieren entre B3/S236 y el autómata celular neuronal con una pérdida objetivo de 0.2.

Por otro lado, todas las reglas aprendidas erróneamente difieren en los patrones de las figuras 1.13a y 1.13b. Ambos patrones se encuentran completos ($C1N7$ y $C1N8$), por lo que ahora sobrevive con 7 y 8 vecinos. La regla aprendida es B3/S23678.



(a) Se intercambió 0 por 1 en $C1N7$ (b) Se intercambió 0 por 1 en $C1N8$

Figura 1.13: Patrones que difieren entre B3/S236 y el autómata celular neuronal con una pérdida objetivo de 0.1.

Los resultados de este primer experimento permiten establecer las siguientes consideraciones clave sobre el entrenamiento de autómatas celulares neuronales:

- La capacidad de generalización de la red neuronal depende del sesgo de muestra por la baja frecuencia de aparición de ciertos patrones (como $C0N8$ o $C1N8$). Es por esto que establecer una pérdida objetivo estricta fuerza a la red a ajustar sus pesos en regiones del espacio donde hay patrones menos representados. El caso contrario atenúa estos estados y lo conduce a otro atractor.

- Se comprueba que el entrenamiento de reglas semitotalísticas no garantiza que la regla aprendida pertenezca al mismo conjunto. Esto se observó en el caso B3/S236 con pérdida de 0.2, ya que no se expone a todas las permutaciones rotacionales de la vecindad. Por lo que patrones equivalentes son tratados de forma independiente, rompiendo la simetría propia de la vecindad.

Estos experimentos confirman que no se requieren arquitecturas neuronales complejas para replicar este tipo de dinámicas evolutivas. Asimismo, queda validada la metodología propuesta para extraer e identificar el vector de regla aprendido por el modelo, sentando las bases para los siguientes experimentos del capítulo.

1.1.1.1. Efecto del tamaño de la vecindad

Al experimentar con automatas celualres ya conocidos, se puede saber el comprotamiento futuro porque la regla nos indica la función de transición, el numero estados y el tamaño de la vecindad. Por lo que los entrenamiento de la red neuronal han requerido como entrada los mismo elementos que forman la vecindad. Sin embargo, en escenarios donde desconocemos la función de transición, no podemos definir con total exactitud la vecindad. Esa por esta razón que los experimentos a continuación buscan identificar como afecta el desconocimiento de la vecindad al momento de intentar replicar el comportamiento de la regla B3/S23.

El juego de la vida se define mediante una regla semitotalistica que diferencía el centro de los bordes. Considerando esto realizaremos 4 pruebas: (1) eliminación del estado central, (2) eliminación de células exteriores, (3) incremento del tamaño de la vecindad y (4) sustitución de elementos de la vecindad. Con esto se busca identificar un método de selección de vecindad que nos permita extraer el comportamiento esencial de un sistema complejo.

Tasa	Lote	Brecha media	Brecha máxima	Segundos
0.0003	1024	0.00038	0.00051	216
0.0003	4096	0.00060	0.00089	58
0.0003	8192	0.00080	0.00122	40
0.001	1024	0.00105	0.00277	213
0.001	4096	0.00042	0.00058	58
0.001	8192	0.00053	0.00070	42
0.003	1024	0.16498	0.29317	210
0.003	4096	0.07681	0.19701	58
0.003	8192	0.01834	0.07159	35

Tabla 1.3: Ajuste de tasa de aprendizaje y tamaño de lote con la red 16:16. Vecindad de 3×3 sin el vecino noroeste, 100 épocas, semilla 42. Brecha: pérdida media de las últimas 10 épocas − pérdida mínima alcanzable (0.121294); media, máximo y segundos medios sobre las 4 configuraciones de activación.

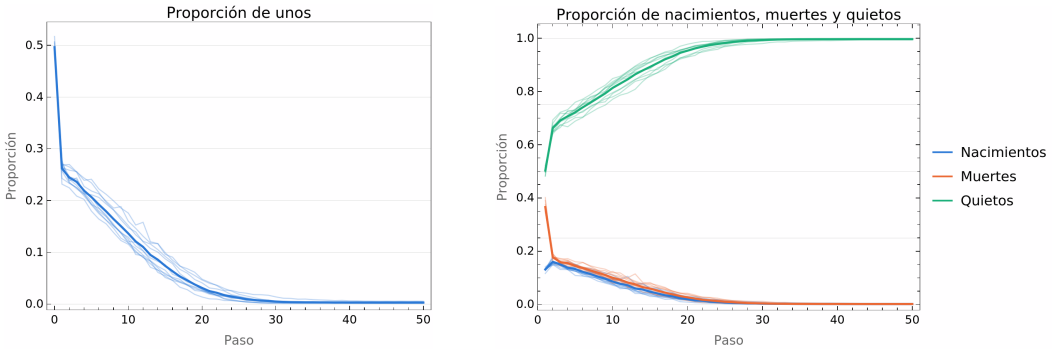
Tasa	Lote	Brecha media	Brecha máxima	Segundos
0.0003	1024	0.00065	0.00087	58
0.0003	4096	0.00055	0.00085	16
0.0003	8192	0.00071	0.00097	10
0.0003	32768	0.01037	0.02178	6
0.001	1024	0.00078	0.00112	57
0.001	4096	0.00056	0.00075	16
0.001	8192	0.00050	0.00068	10
0.001	32768	0.00094	0.00130	5
0.003	1024	0.00037	0.00049	57
0.003	4096	0.00074	0.00107	16
0.003	8192	0.00068	0.00084	9
0.003	32768	0.00053	0.00067	5
0.01	1024	0.00055	0.00074	57
0.01	4096	0.00062	0.00085	16
0.01	8192	0.00077	0.00104	9
0.01	32768	0.00078	0.00104	4

Tabla 1.4: Ajuste de tasa de aprendizaje y tamaño de lote con la red 2:16. Vecindad de 3×3 sin el vecino noroeste, 100 épocas, semilla 42. Brecha: pérdida media de las últimas 10 épocas − pérdida mínima alcanzable (0.121294); media, máximo y segundos medios sobre las 4 configuraciones de activación.

Como primer experimento se ignora la célula del centro. Como se observa en la tabla 1.5, ninguna de las configuraciones tuvo una perdida menor al 0.07. Es imposible extraer el comportamiento de B3/S23 sin conocer la información del centro, sin embargo, la configuración 16:16:ReLU & 1:Sigmoid genera un vector de regla que difiere en 28 de 512 elementos (5.46875 %) si lo consideramos como una regla tradicional. Su evolución tiende a eliminar todos los estados 1 y genera pocas configuraciones estáticas y cíclicas en menos de 50 pasos, tal como se muestran en las figuras 1.14.

Capa Oculta	**Capa Salida**	**Pérdida**
16:16:ReLU	2:Linear	0.078754
16:16:TanH	1:Sigmoid	0.078889
16:16:TanH	2:Linear	0.078603
16:16:Sigmoid	2:Linear	0.414097
16:16:ReLU	1:Sigmoid	0.078445

Tabla 1.5: Comparativa de rendimiento con múltiples hiperparámetros de la regla B3/S23: Pérdida objetivo 0.001, límite de épocas: 1000, tamaño del lote: 8192, tasa de aprendizaje: 0.001, semilla aleatoria: 42.



(a) Proporción de unos en cada paso evolutivo.

(b) Porcentaje nacimientos, muertes y células sin cambios en cada paso evolutivo.

Figura 1.14: Proporciones de estados y cambios de estados en 10 evoluciones con condiciones iniciales aleatorias durante 50 pasos con el autómata celular neuronal obtenido por 16:16:ReLU & 1:Sigmoid.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	500	0.088437	0.009787	28	0.0523	0.1163	0.0005
2:8:ReLU	2:Linear	500	0.085921	0.007271	28	0.0529	0.1176	0.0018
4:8:ReLU	2:Linear	500	0.078934	0.000284	28	0.0537	0.1185	0.0029
4:16:ReLU	2:Linear	500	0.078685	0.000035	28	0.0537	0.1185	0.0029
8:16:ReLU	2:Linear	500	0.078674	0.000023	28	0.0537	0.1185	0.0029
16:16:ReLU	2:Linear	500	0.078720	0.000070	28	0.0537	0.1185	0.0029
1:4:TanH	1:Sigmoid	500	0.081676	0.003026	28	0.0534	0.1185	0.0033
2:8:TanH	1:Sigmoid	500	0.078866	0.000216	28	0.0537	0.1185	0.0029
4:8:TanH	1:Sigmoid	500	0.078713	0.000063	28	0.0537	0.1185	0.0029
4:16:TanH	1:Sigmoid	500	0.078670	0.000020	28	0.0537	0.1185	0.0029
8:16:TanH	1:Sigmoid	500	0.078671	0.000021	28	0.0537	0.1185	0.0029
16:16:TanH	1:Sigmoid	500	0.078707	0.000057	28	0.0537	0.1185	0.0029
1:4:TanH	2:Linear	500	0.082283	0.003633	28	0.0528	0.1168	0.0016
2:8:TanH	2:Linear	500	0.078758	0.000108	28	0.0537	0.1185	0.0029
4:8:TanH	2:Linear	500	0.078716	0.000066	28	0.0537	0.1185	0.0029
4:16:TanH	2:Linear	500	0.078685	0.000035	28	0.0537	0.1185	0.0029
8:16:TanH	2:Linear	500	0.078680	0.000030	28	0.0537	0.1185	0.0029
16:16:TanH	2:Linear	500	0.078900	0.000250	28	0.0537	0.1185	0.0029
1:4:ReLU	1:Sigmoid	500	0.168493	0.089843	70	0.1336	0.1160	0.0000
2:8:ReLU	1:Sigmoid	500	0.080522	0.001872	28	0.0535	0.1187	0.0034
4:8:ReLU	1:Sigmoid	500	0.078796	0.000146	28	0.0537	0.1185	0.0029
4:16:ReLU	1:Sigmoid	500	0.078688	0.000038	28	0.0537	0.1185	0.0029
8:16:ReLU	1:Sigmoid	500	0.078679	0.000029	28	0.0537	0.1185	0.0029
16:16:ReLU	1:Sigmoid	500	0.078671	0.000021	28	0.0537	0.1185	0.0029

Tabla 1.6: Regla B3/S23 sin la célula central. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.078650. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

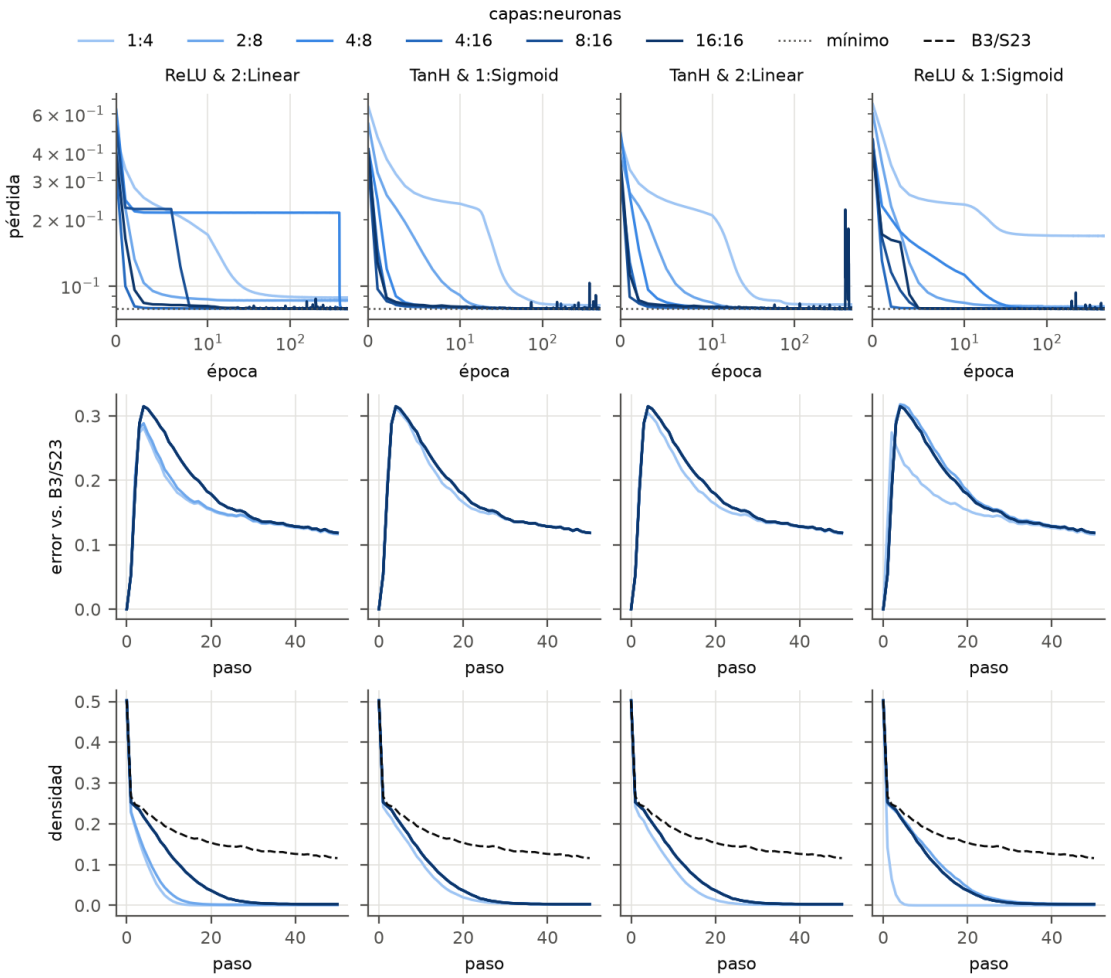


Figura 1.15: Regla B3/S23 sin la célula central. Fila 1: pérdida por época (línea punteada: pérdida mínima alcanzable). Fila 2: fracción de células distintas a B3/S23 por paso. Fila 3: fracción de células vivas por paso (línea discontinua: B3/S23). Filas 2 y 3: promedio de 10 condiciones iniciales aleatorias.

Por otro lado, la tabla 1.7

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	500	0.124695	0.003401	98	0.1888	0.1348	0.0238
2:8:ReLU	2:Linear	500	0.122691	0.001397	98	0.1893	0.1356	0.0261
4:8:ReLU	2:Linear	500	0.121956	0.000662	98	0.1887	0.1371	0.0272
4:16:ReLU	2:Linear	500	0.121646	0.000352	98	0.1890	0.1354	0.0254
8:16:ReLU	2:Linear	500	0.121453	0.000159	98	0.1890	0.1354	0.0254
16:16:ReLU	2:Linear	500	0.121473	0.000179	98	0.1890	0.1354	0.0254
1:4:TanH	1:Sigmoid	500	0.146544	0.025250	98	0.1891	0.1496	0.0429
2:8:TanH	1:Sigmoid	500	0.121963	0.000669	98	0.1889	0.1335	0.0234
4:8:TanH	1:Sigmoid	500	0.121544	0.000250	98	0.1890	0.1354	0.0254
4:16:TanH	1:Sigmoid	500	0.121433	0.000139	98	0.1890	0.1354	0.0254
8:16:TanH	1:Sigmoid	500	0.121434	0.000140	98	0.1890	0.1354	0.0254
16:16:TanH	1:Sigmoid	500	0.121510	0.000216	98	0.1890	0.1354	0.0254
1:4:TanH	2:Linear	500	0.122987	0.001693	98	0.1890	0.1302	0.0192
2:8:TanH	2:Linear	500	0.122124	0.000830	98	0.1890	0.1323	0.0203
4:8:TanH	2:Linear	500	0.121537	0.000243	98	0.1888	0.1322	0.0215
4:16:TanH	2:Linear	500	0.121453	0.000159	98	0.1887	0.1339	0.0238
8:16:TanH	2:Linear	500	0.121432	0.000138	98	0.1890	0.1354	0.0254
16:16:TanH	2:Linear	500	0.121528	0.000234	98	0.1886	0.1364	0.0260
1:4:ReLU	1:Sigmoid	500	0.123439	0.002145	98	0.1890	0.1326	0.0232
2:8:ReLU	1:Sigmoid	500	0.123578	0.002284	98	0.1891	0.1303	0.0197
4:8:ReLU	1:Sigmoid	500	0.122326	0.001032	98	0.1888	0.1327	0.0224
4:16:ReLU	1:Sigmoid	500	0.121524	0.000230	98	0.1886	0.1364	0.0260
8:16:ReLU	1:Sigmoid	500	0.121457	0.000163	98	0.1888	0.1322	0.0215
16:16:ReLU	1:Sigmoid	500	0.121469	0.000175	98	0.1890	0.1354	0.0254

Tabla 1.7: Regla B3/S23 sin el vecino noroeste $(-1, -1)$. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.121294. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

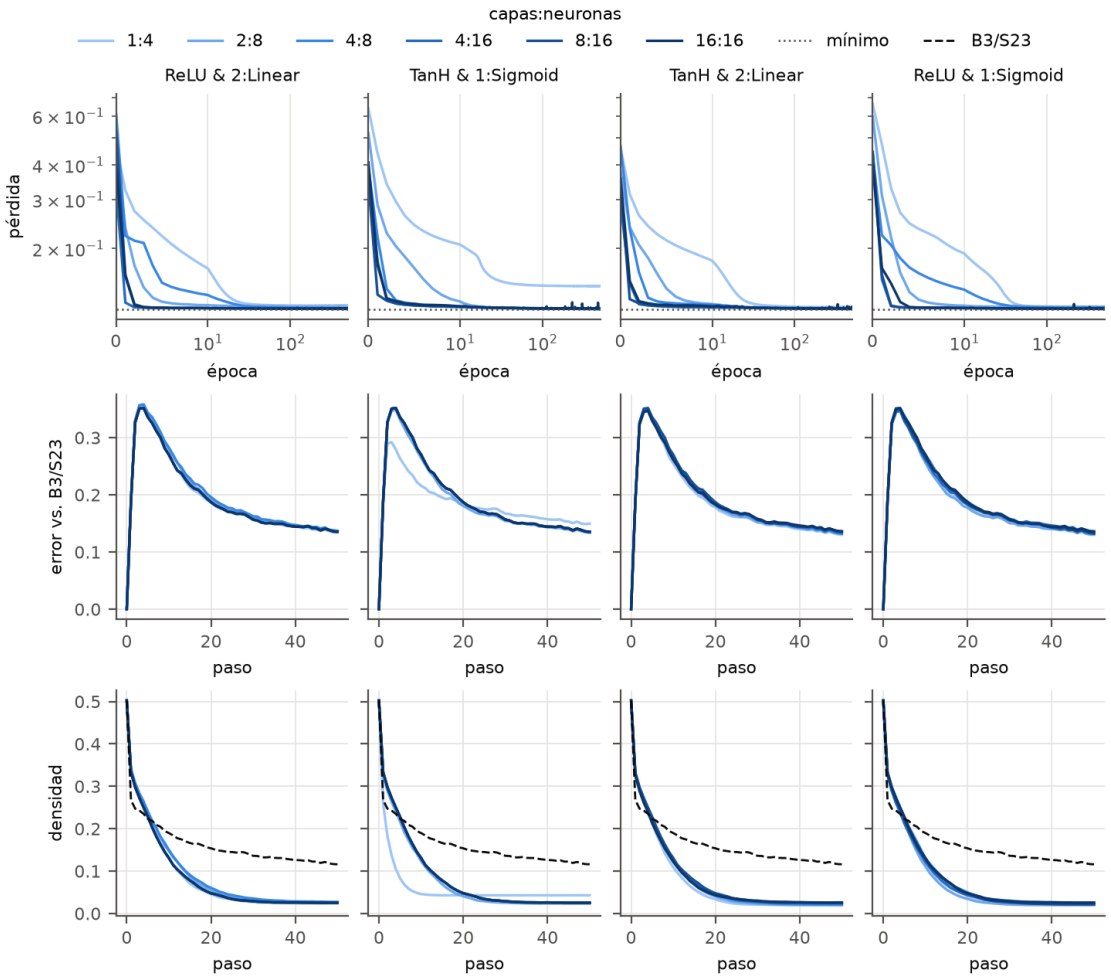


Figura 1.16: Regla B3/S23 sin el vecino noroeste $(-1, -1)$. Mismas filas que la figura 1.15.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	500	0.122197	0.003785	98	0.1894	0.1294	0.0169
2:8:ReLU	2:Linear	500	0.120552	0.002140	98	0.1890	0.1197	0.0048
4:8:ReLU	2:Linear	500	0.208683	0.090271	354	0.6965	0.8840	1.0000
4:16:ReLU	2:Linear	500	0.118567	0.000155	98	0.1887	0.1177	0.0022
8:16:ReLU	2:Linear	500	0.118518	0.000106	98	0.1889	0.1231	0.0101
16:16:ReLU	2:Linear	500	0.118545	0.000133	98	0.1887	0.1292	0.0158
1:4:TanH	1:Sigmoid	500	0.121592	0.003180	98	0.1890	0.1244	0.0120
2:8:TanH	1:Sigmoid	500	0.119090	0.000678	98	0.1887	0.1188	0.0037
4:8:TanH	1:Sigmoid	500	0.118605	0.000193	98	0.1890	0.1182	0.0032
4:16:TanH	1:Sigmoid	500	0.118499	0.000087	98	0.1893	0.1281	0.0158
8:16:TanH	1:Sigmoid	500	0.118477	0.000065	98	0.1893	0.1281	0.0158
16:16:TanH	1:Sigmoid	500	0.118552	0.000140	98	0.1897	0.1180	0.0027
1:4:TanH	2:Linear	500	0.120355	0.001943	98	0.1885	0.1209	0.0061
2:8:TanH	2:Linear	500	0.118989	0.000577	98	0.1890	0.1176	0.0021
4:8:TanH	2:Linear	500	0.118644	0.000232	98	0.1892	0.1180	0.0028
4:16:TanH	2:Linear	500	0.118511	0.000099	98	0.1891	0.1256	0.0127
8:16:TanH	2:Linear	500	0.118491	0.000079	98	0.1892	0.1198	0.0050
16:16:TanH	2:Linear	500	0.118562	0.000150	98	0.1888	0.1177	0.0022
1:4:ReLU	1:Sigmoid	500	0.121933	0.003521	98	0.1897	0.1276	0.0142
2:8:ReLU	1:Sigmoid	500	0.121536	0.003124	98	0.1891	0.1185	0.0033
4:8:ReLU	1:Sigmoid	500	0.118923	0.000511	98	0.1891	0.1214	0.0061
4:16:ReLU	1:Sigmoid	500	0.118516	0.000104	98	0.1892	0.1204	0.0061
8:16:ReLU	1:Sigmoid	500	0.118541	0.000129	98	0.1888	0.1210	0.0070
16:16:ReLU	1:Sigmoid	500	0.118566	0.000154	98	0.1893	0.1281	0.0158

Tabla 1.8: Regla B3/S23 sin el vecino norte $(0, -1)$. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.118412. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

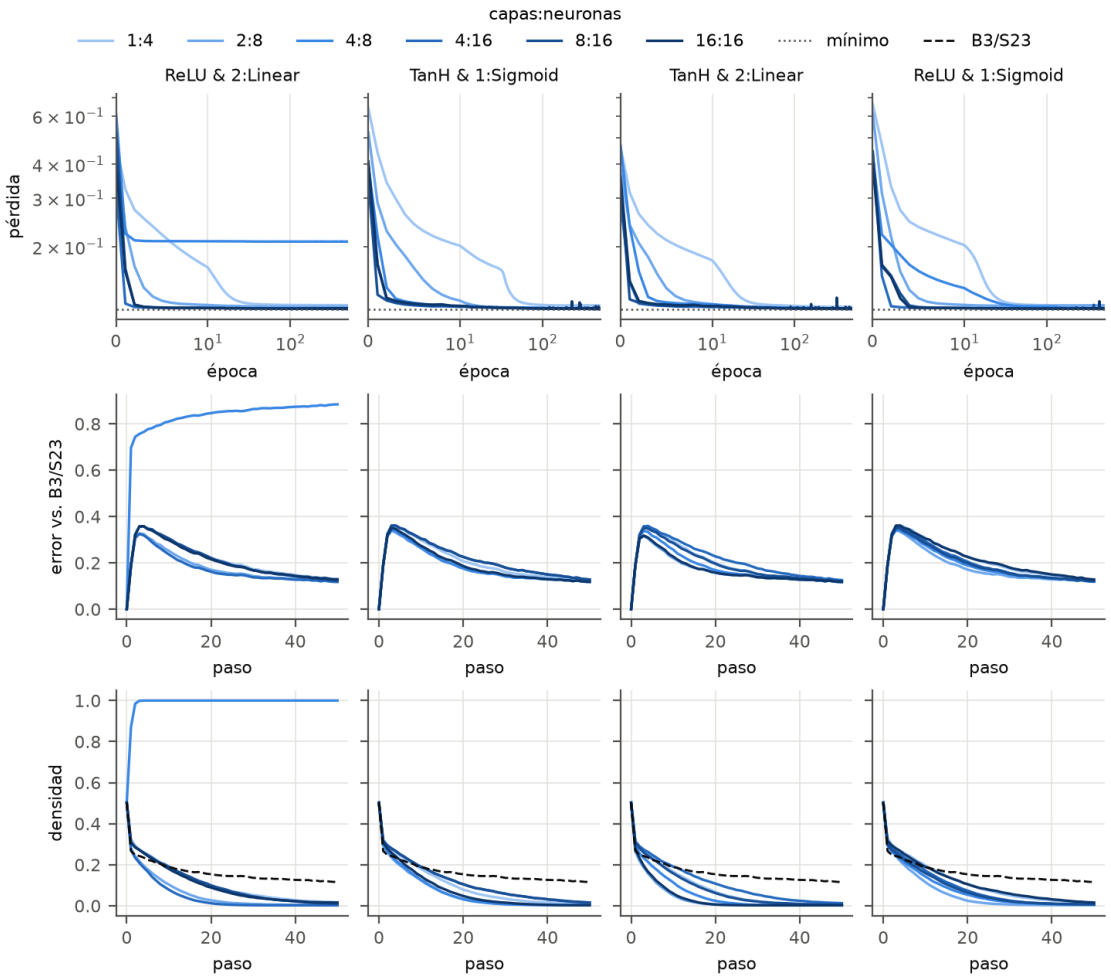


Figura 1.17: Regla B3/S23 sin el vecino norte $(0, -1)$. Mismas filas que la figura 1.15.

1.1.2. Incremento de vecindad

Por otro lado, los resultados

TODO:

muestran que el incremento de la vecindad no afecta el replicameinto del comportamiento, la red nueornal sigue pudiendo aprender la regla sin saturarla. Ciertamente, el numero de épocas requeridas también cambia según la demanda que obtenga, esto se debe principalmente ya que considera algunos pasos para matar

las células cuyas entradas provienen de esas vecindades extras.

Por otro lado, la susitución depende específicamente de donde se esta obteniendo y el tamaño de la vecindad que lo define. Esto se convirte en 2 problemas, intentar definir el estado de la celula faltante con lso estados actuales de sus vecinos y luego utilizar ese dato adicional para definir el estado actual.

Es necesario notar que B3/S23 es muy sensible a un estado que vale un 1 o un 0, porque un único bit marca la diferente entre B24/S1234. Es por esto que el siguiente experimento utiliza una regla high life

TODO: definir regla high life

que muestra los siguientes resultados.

Podemos concluir entonces el valor de la vecindad.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	38	0.000923	0.000923	0	0.0000	0.0000	0.1160
2:8:ReLU	2:Linear	28	0.000933	0.000933	0	0.0000	0.0000	0.1160
4:8:ReLU	2:Linear	5	0.000942	0.000942	0	0.0000	0.0000	0.1160
4:16:ReLU	2:Linear	4	0.000372	0.000372	0	0.0000	0.0000	0.1160
8:16:ReLU	2:Linear	3	0.000012	0.000012	0	0.0000	0.0000	0.1160
16:16:ReLU	2:Linear	3	0.000003	0.000003	0	0.0000	0.0000	0.1160
1:4:TanH	1:Sigmoid	55	0.000998	0.000998	0	0.0000	0.0000	0.1160
2:8:TanH	1:Sigmoid	20	0.000867	0.000867	0	0.0000	0.0000	0.1160
4:8:TanH	1:Sigmoid	11	0.000948	0.000948	0	0.0000	0.0000	0.1160
4:16:TanH	1:Sigmoid	5	0.000951	0.000951	0	0.0000	0.0000	0.1160
8:16:TanH	1:Sigmoid	5	0.000945	0.000945	0	0.0000	0.0000	0.1160
16:16:TanH	1:Sigmoid	6	0.000918	0.000918	0	0.0000	0.0000	0.1160
1:4:TanH	2:Linear	500	0.079526	0.079526	35	0.0673	0.1446	0.0371
2:8:TanH	2:Linear	14	0.000880	0.000880	0	0.0000	0.0000	0.1160
4:8:TanH	2:Linear	7	0.000987	0.000987	0	0.0000	0.0000	0.1160
4:16:TanH	2:Linear	4	0.000742	0.000742	0	0.0000	0.0000	0.1160
8:16:TanH	2:Linear	3	0.000612	0.000612	0	0.0000	0.0000	0.1160
16:16:TanH	2:Linear	3	0.000848	0.000848	0	0.0000	0.0000	0.1160
1:4:ReLU	1:Sigmoid	500	0.097058	0.097058	46	0.0872	0.1448	0.0391
2:8:ReLU	1:Sigmoid	16	0.000828	0.000828	0	0.0000	0.0000	0.1160
4:8:ReLU	1:Sigmoid	45	0.000954	0.000954	0	0.0000	0.0000	0.1160
4:16:ReLU	1:Sigmoid	3	0.000646	0.000646	0	0.0000	0.0000	0.1160
8:16:ReLU	1:Sigmoid	3	0.000021	0.000021	0	0.0000	0.0000	0.1160
16:16:ReLU	1:Sigmoid	3	0.000053	0.000053	0	0.0000	0.0000	0.1160

Tabla 1.9: Regla B3/S23 con vecindad de 3×3. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.000000. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

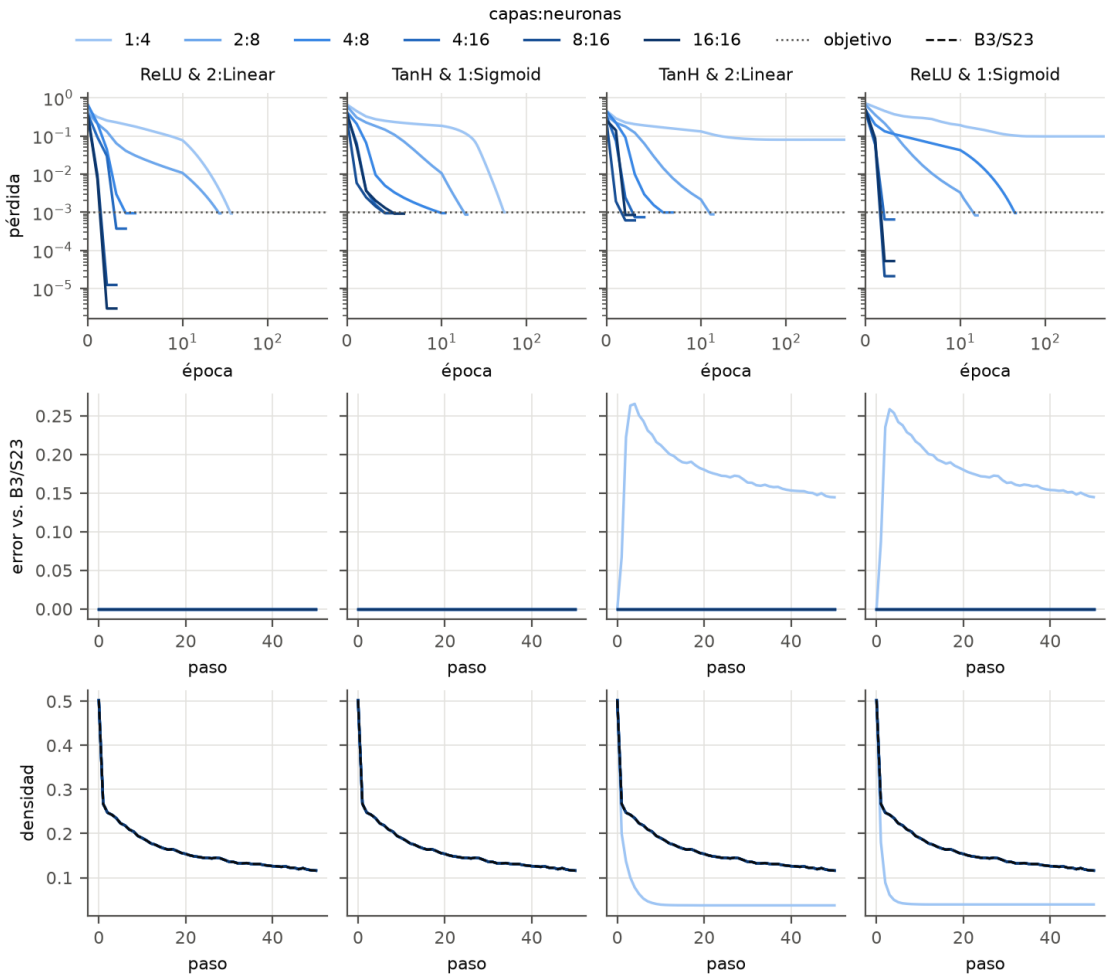


Figura 1.18: Regla B3/S23 con vecindad de 3×3. Mismas filas que la figura 1.15; en la fila 1 la línea punteada es la pérdida objetivo.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	38	0.000975	0.000975	0	0.0000	0.0000	0.1160
2:8:ReLU	2:Linear	11	0.000747	0.000747	0	0.0000	0.0000	0.1160
4:8:ReLU	2:Linear	500	0.159375	0.159375	326	0.6425	0.8840	1.0000
4:16:ReLU	2:Linear	19	0.000035	0.000035	0	0.0000	0.0000	0.1160
8:16:ReLU	2:Linear	3	0.000062	0.000062	0	0.0000	0.0000	0.1160
16:16:ReLU	2:Linear	3	0.000332	0.000332	0	0.0007	0.2190	0.1370
1:4:TanH	1:Sigmoid	53	0.000962	0.000962	0	0.0000	0.0000	0.1160
2:8:TanH	1:Sigmoid	18	0.000948	0.000948	0	0.0000	0.0000	0.1160
4:8:TanH	1:Sigmoid	11	0.000898	0.000898	0	0.0000	0.0000	0.1160
4:16:TanH	1:Sigmoid	6	0.000854	0.000854	0	0.0000	0.0000	0.1160
8:16:TanH	1:Sigmoid	6	0.000837	0.000837	0	0.0000	0.0000	0.1160
16:16:TanH	1:Sigmoid	7	0.000722	0.000722	0	0.0000	0.0043	0.1159
1:4:TanH	2:Linear	37	0.000936	0.000936	0	0.0000	0.0000	0.1160
2:8:TanH	2:Linear	17	0.000868	0.000868	0	0.0000	0.0000	0.1160
4:8:TanH	2:Linear	8	0.000783	0.000783	0	0.0000	0.0000	0.1160
4:16:TanH	2:Linear	4	0.000652	0.000652	0	0.0000	0.0000	0.1160
8:16:TanH	2:Linear	4	0.000708	0.000708	0	0.0000	0.0000	0.1160
16:16:TanH	2:Linear	3	0.000852	0.000852	0	0.0000	0.0074	0.1169
1:4:ReLU	1:Sigmoid	49	0.000882	0.000882	0	0.0000	0.0000	0.1160
2:8:ReLU	1:Sigmoid	43	0.000971	0.000971	0	0.0000	0.0000	0.1160
4:8:ReLU	1:Sigmoid	10	0.000545	0.000545	0	0.0000	0.0000	0.1160
4:16:ReLU	1:Sigmoid	3	0.000768	0.000768	0	0.0000	0.0000	0.1160
8:16:ReLU	1:Sigmoid	43	0.000926	0.000926	0	0.0000	0.0000	0.1160
16:16:ReLU	1:Sigmoid	4	0.000225	0.000225	0	0.0000	0.0000	0.1160

Tabla 1.10: Regla B3/S23 con vecindad de 5×5. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.000000. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

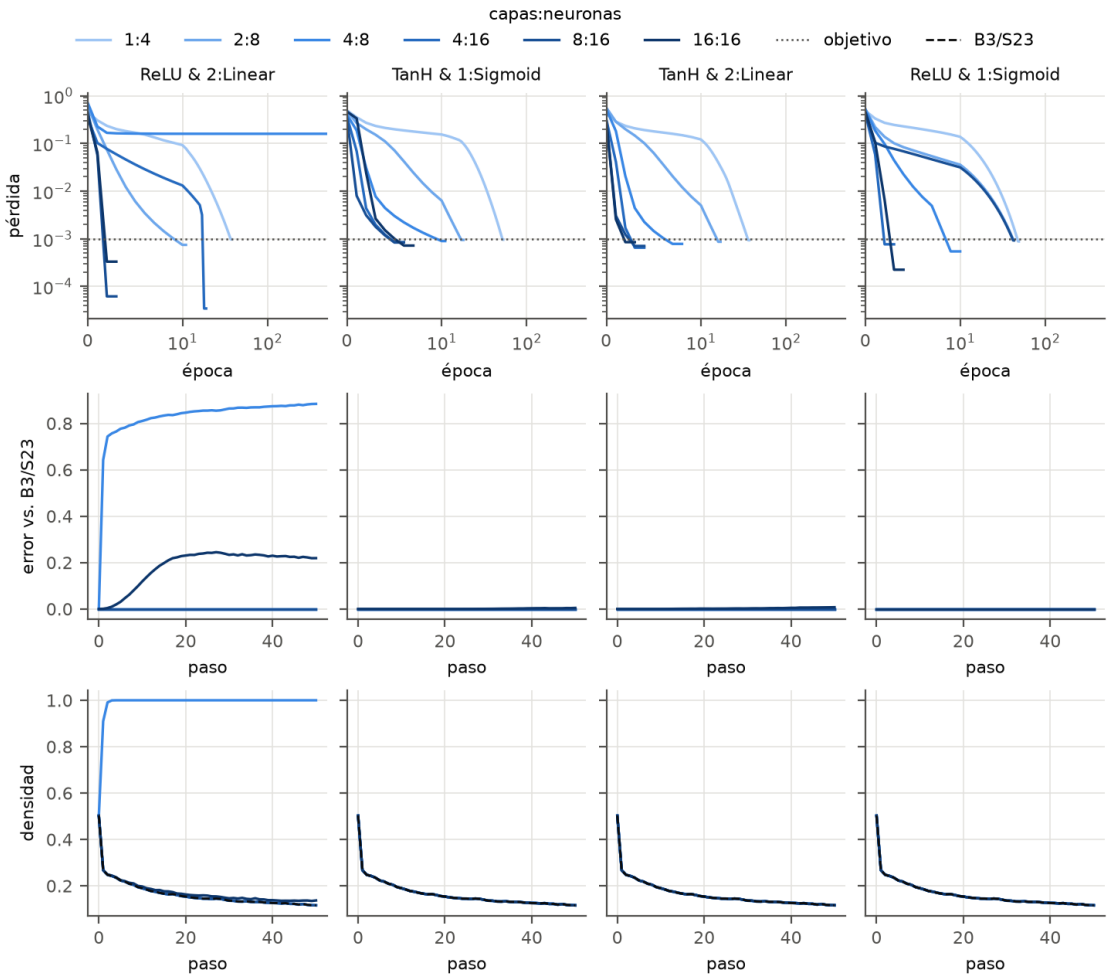


Figura 1.19: Regla B3/S23 con vecindad de 5×5. Mismas filas que la figura 1.18.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	500	0.103870	0.103870	56	0.1075	0.1291	0.0170
2:8:ReLU	2:Linear	14	0.000885	0.000885	0	0.0000	0.0000	0.1160
4:8:ReLU	2:Linear	10	0.000656	0.000656	0	0.0000	0.0000	0.1160
4:16:ReLU	2:Linear	3	0.000526	0.000526	0	0.0000	0.0000	0.1160
8:16:ReLU	2:Linear	5	0.000023	0.000023	0	0.0000	0.0098	0.1163
16:16:ReLU	2:Linear	3	0.000188	0.000188	0	0.0000	0.0011	0.1163
1:4:TanH	1:Sigmoid	55	0.000953	0.000953	0	0.0000	0.0000	0.1160
2:8:TanH	1:Sigmoid	19	0.000813	0.000813	0	0.0000	0.0000	0.1160
4:8:TanH	1:Sigmoid	11	0.000839	0.000839	0	0.0000	0.0000	0.1160
4:16:TanH	1:Sigmoid	5	0.000827	0.000827	0	0.0000	0.0000	0.1160
8:16:TanH	1:Sigmoid	6	0.000880	0.000880	0	0.0000	0.0000	0.1160
16:16:TanH	1:Sigmoid	7	0.000962	0.000962	0	0.0000	0.0053	0.1172
1:4:TanH	2:Linear	46	0.000905	0.000905	0	0.0000	0.0000	0.1160
2:8:TanH	2:Linear	16	0.000903	0.000903	0	0.0000	0.0000	0.1160
4:8:TanH	2:Linear	8	0.000865	0.000865	0	0.0000	0.0000	0.1160
4:16:TanH	2:Linear	4	0.000686	0.000686	0	0.0000	0.0000	0.1160
8:16:TanH	2:Linear	4	0.000633	0.000633	0	0.0000	0.0100	0.1175
16:16:TanH	2:Linear	4	0.000497	0.000497	0	0.0000	0.0562	0.1174
1:4:ReLU	1:Sigmoid	54	0.000909	0.000909	0	0.0000	0.0000	0.1160
2:8:ReLU	1:Sigmoid	14	0.000803	0.000803	0	0.0000	0.0000	0.1160
4:8:ReLU	1:Sigmoid	43	0.000928	0.000928	0	0.0000	0.0000	0.1160
4:16:ReLU	1:Sigmoid	5	0.000137	0.000137	0	0.0000	0.0000	0.1160
8:16:ReLU	1:Sigmoid	3	0.000045	0.000045	0	0.0000	0.0000	0.1160
16:16:ReLU	1:Sigmoid	5	0.000152	0.000152	0	0.0002	0.0887	0.1174

Tabla 1.11: Regla B3/S23 con vecindad de 7×7. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.000000. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

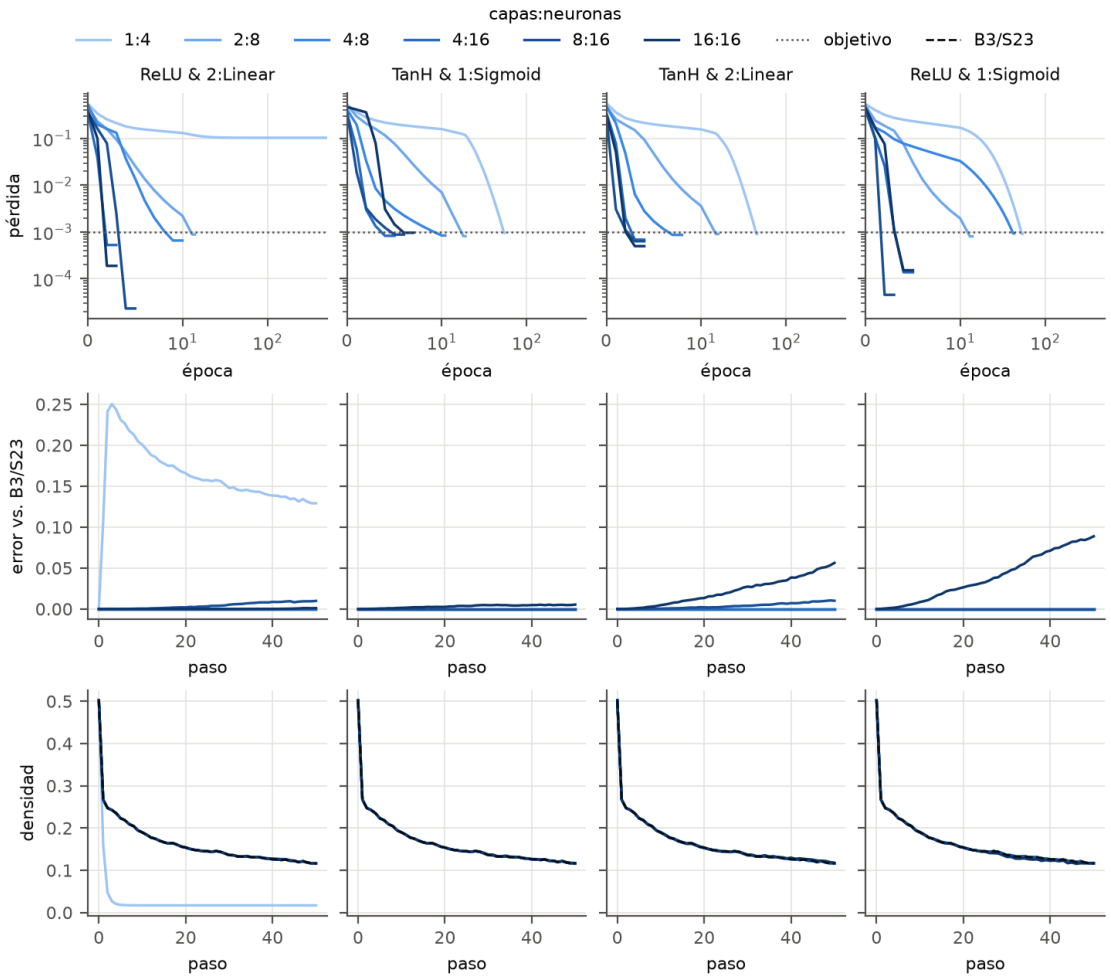


Figura 1.20: Regla B3/S23 con vecindad de 7×7. Mismas filas que la figura 1.18.

Capa Oculta	Capa Salida	Épocas	Pérdida	Brecha	Patrones distintos	Error paso 1	Error paso 50	Densidad paso 50
1:4:ReLU	2:Linear	500	0.103870	0.103870	56	0.1074	0.1291	0.0170
2:8:ReLU	2:Linear	30	0.000985	0.000985	0	0.0000	0.0000	0.1160
4:8:ReLU	2:Linear	5	0.000792	0.000792	0	0.0000	0.0000	0.1160
4:16:ReLU	2:Linear	4	0.000302	0.000302	0	0.0000	0.0000	0.1160
8:16:ReLU	2:Linear	3	0.000063	0.000063	0	0.0002	0.0414	0.1175
16:16:ReLU	2:Linear	4	0.000336	0.000336	0	0.0000	0.0332	0.1163
1:4:TanH	1:Sigmoid	57	0.000913	0.000913	0	0.0000	0.0000	0.1160
2:8:TanH	1:Sigmoid	19	0.000913	0.000913	0	0.0000	0.0000	0.1160
4:8:TanH	1:Sigmoid	11	0.000823	0.000823	0	0.0000	0.0000	0.1160
4:16:TanH	1:Sigmoid	5	0.000826	0.000826	0	0.0000	0.0000	0.1160
8:16:TanH	1:Sigmoid	6	0.000786	0.000786	0	0.0000	0.0000	0.1160
16:16:TanH	1:Sigmoid	6	0.000802	0.000802	0	0.0000	0.0018	0.1157
1:4:TanH	2:Linear	39	0.000976	0.000976	0	0.0000	0.0000	0.1160
2:8:TanH	2:Linear	15	0.000948	0.000948	0	0.0000	0.0000	0.1160
4:8:TanH	2:Linear	8	0.000871	0.000871	0	0.0000	0.0000	0.1160
4:16:TanH	2:Linear	4	0.000547	0.000547	0	0.0000	0.0000	0.1160
8:16:TanH	2:Linear	3	0.000746	0.000746	0	0.0000	0.0063	0.1154
16:16:TanH	2:Linear	5	0.000742	0.000742	0	0.0001	0.1051	0.1180
1:4:ReLU	1:Sigmoid	500	0.103871	0.103871	56	0.1074	0.1291	0.0170
2:8:ReLU	1:Sigmoid	39	0.000927	0.000927	0	0.0000	0.0000	0.1160
4:8:ReLU	1:Sigmoid	41	0.000944	0.000944	0	0.0000	0.0000	0.1160
4:16:ReLU	1:Sigmoid	4	0.000425	0.000425	0	0.0000	0.0000	0.1160
8:16:ReLU	1:Sigmoid	3	0.000141	0.000141	0	0.0000	0.0037	0.1157
16:16:ReLU	1:Sigmoid	21	0.000156	0.000156	0	0.0001	0.0590	0.1198

Tabla 1.12: Regla B3/S23 con vecindad de 8×8. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.000000. Brecha: pérdida final − pérdida mínima. Patrones: centros distintos a B3/S23 de los 512 patrones tras un paso. Error k: fracción de células distintas a B3/S23 en el paso k y Densidad 50: fracción de células vivas en el paso 50, ambas promedio de 10 condiciones iniciales aleatorias de 69×69 (B3/S23: 0.1160).

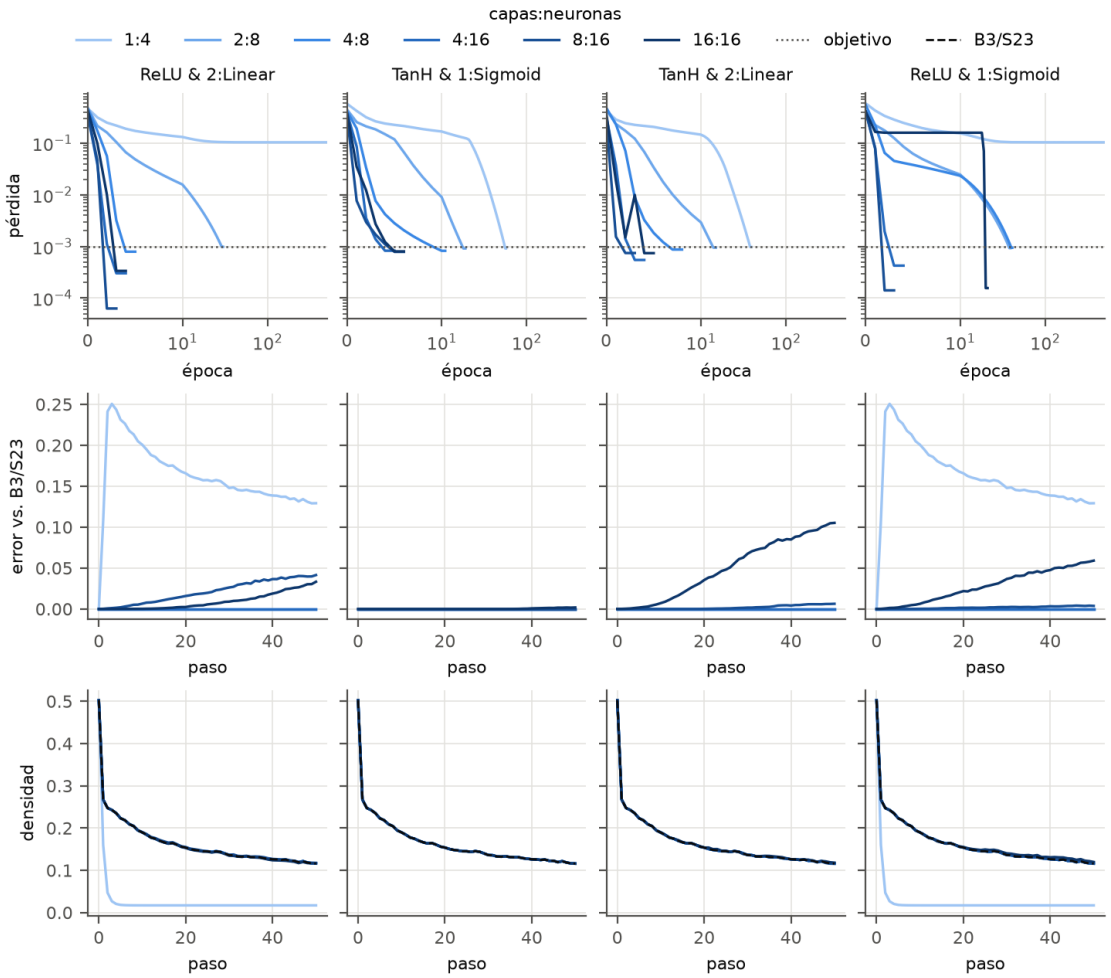


Figura 1.21: Regla B3/S23 con vecindad de 8×8 (desplazamientos -4 a 3 en cada eje, el máximo que admite el kernel). Mismas filas que la figura 1.18.

1.1.3. Sandpile

Para finalizar esta primer serie de experimentos, se busca replicar el comportamiento de un sistema autoorganizado llamado SandPile porpuesto por

TODO: \cite

. Es un sistema en donde hay pilas de arena que icnrementan, pero, cuando se acumulan 5 granos, los 4 a arriba se se dispersan de manera uniformen sus cuatro vecinos equidistantes mas cercanos.

Esta versión únicamente espera que se terminen de acomodar todos los granos de arena se suelta el siguiente en el centro o puede que en cada paso siempre se añada un grano de arena. El primero no puede tener una representación como automata celular ya que lpara cambiar un estado es necesario que el sistema se encuentre en equilibrio, y eso va en contra de la naturaleza de los autómatas celuales pues el único conocimiento es de su vecindad. Es por esto que se propone un conjunto de estados adicionales que sean los generadores de arena, por lo que tendremos 3 tipos de espacios, arena normal, vacio y arena generadora. Esto se puede definir entonces como $5 + 5 + 1$ estados.

Con 11 estados y 5 vecinos, existen 11^5 configuraciones. La regla parece simple, si tengo 5 disperso 4 de ellas, pero si nos ponemos en el lugar de cada una de las células, cambia la perspectiva. Porque no es lo mismo que tenga 5 y mis vecinos también tengan 5, o que solo un vecino tenga 5 o 2. Si soy el único disperso y me quedo con 1. Si tengo a n vecinos mi tamaño aumenta a $1 + n$ pero si tengo 4 vecinos en 5, paso de 5 a 5. Una función matematica sencilla, pero que el CA lo diferencia en casos.

Los datos no son obtenidos mediante la representación del automata celular, sino son obtenidos mediante la simulación de sandpile y el objetivo es obtener la regla del CA que pueda replicar ese comportamiento.

En

TODO:

vemos los resultados de de la simulación con el entrenamiento. El sistema aprendio el comportamiento considerando un solo generador. En

TODO:

se muestran los resultados de la evolución pero considerando multiple puntos generadores.

La reducción de vecindad afecta completamente el comportamiento, eliminar el centro le quita a las células conocer su altura, y eliminar cualquier vecino rompe la información por si algún vecino tiene arena que pasarle.

El NCA es mas complicado que la función propia del juego. Sin embargo, esta prueba esta realizada en un ambiente que ya conocemos y cumple el objetivo. Replicar el comportamiento de un sistema para posteriormente simular las reglas de ese sistema complejo pero en diferentes situaciones, es decir, los experimentos realizados con multiples generadores.

1.1.4. Hormiga de Langton

Para comprobar los resultados de comprotamientos ya conocidos, se realiza un análisis similar la hormiga de Langton. La hormiga de Langton es un agente en una grilla bidimensional que sigue instrucciones sencillas, lee un estado, el estado define su neuva dirección y se mueve a ella, similar a una maquina de Turing pero en 2 dimensiones, también conocido como turmite.

Este sistema puede ser representado mediante un automata celular, cuyos estados esta dado por la unión de los estados del tablero $\cup$ estados que definen la dirección de la hormiga, para la definición mas pequeña, tendraimos 8 estados en una vecindad de Neumman, por lo que su vector seria de $2^5 = 32$ elementos, por lo que la hormiga de Langton es una regla de $2^32 = 4294967296$ reglas, por lo que usamos el NCA para extraer el comportamiento del agente de la hormiga.

Las figuras

TODO:

muestran un análisis estadístico del balanceo de clases y el balanceo de entradas, lo que nos indica que

TODO:

.

Siguiendo la misma configuración que con las reglas life, se muestra que puede replicar el comportamiento de la hormiga de Langton. En la figura

TODO:

se muestra la carretera producida después de

TODO: 100

pasos producida tanto por la hormiga de Langton como por el NCA.

el NCA fue entrenado con una sola hormiga, sin embargo, con este comportamiento individual nos preguntamos ¿Cómo generaliza esto a multiples hormigas?

Por otro lado, el entrenamiento con multiples hormigas depende de las restricciones que se definan cuando una hormiga se encuentra con otra. ¿Se tienen que esperar?, ¿Ambas puedan ocupar la misma celda pero cada una maneja su estado independiente? o ¿se eliminan las hormigas?. Estas restricciones son las que definen

las reglas que el automata celular neuronal va a replicar, y son datos que tenemos que considerar. Por ejemplo, si se pueden sobreponer las hormigas, entonces ahora puede haber hasta

TODO: $|15| \cup estados$

total de estados. ya que Si hay una sola hormiga, puede tener 4 direcciones (u,d,l,r), si tengo 2 hormigas puedo tener (ur, ud, ul, rd,rl, dl), si tengo 3 hormigas puedo tener: (urd, url, udl, rdl) y con 4 (el máximo posible) solo tengo una posibilidad (urdl). Esto se debe a que esta configuración solo considera que todas las hormigas tienen la misma regla. Si consideramos que existen tipos de hormigas, entonces el numero de estados crece significamente porque ahora 2 hormigas diferentes pueden tener la misma dirección en la misma celula al mismo tiempo pero sin ser iguales, por lo que el numero de estados aumenta a la combinatoria de 1 en 4 direcciones, 2 en 4, 3 en 4 y 4 en 4 $\cup$ estados.

Es por esto, que esta prueba esta diseñada para medir la capacidad de replicamiento de reglas con un incremento de estados sustancial. Para cumplir uno de los objetivos de esta investigación, repicamiento de comportamientos cuyo definición manual sea complicada. Los resultados se muestran en la figura

TODO:

.

Finalmente, replicamos los experimentos de cambios en la vecindad. Si eliminamos el centro vemos que no afecta para una única hormiga, ya que no import alo que tenga dentro, si tiene una hormiga aputnando a el entonces cambia el estado, y si en el siguiente paso no tiene ninguna hormiga apuntando a el, entonces su estado es 0. Es decir, el único escenario en que mi estado es diferente de 0 es cuando tengo una hormiga aputnando a la celula en uno d esus vecinos.

TODO: Diferenciar el comportamiento de cuando es una hormiga y cuando hay muchas hormigas

Por otro lado, como se muestra con las figuras

TODO:

, se aprecia que la eliminación de cualquier otro elemento en la vecindad si compromete completamente la evolución del automata celular.

1.2. Replicación de sistemas complejos naturales

En este experimento las evoluciones de entrenamiento no provienen de una regla conocida, sino de observaciones de sistemas reales: un incendio forestal visto desde un dron (sección 1.2.1), el desarrollo de embriones en una incubadora con cámara (sección 1.2.2) y el movimiento y división de células en cultivo (sección 1.2.3). Los tres comparten las características que permiten modelarlos como un autómata celular: se observan como una malla bidimensional con encuadre fijo, el estado de cada región depende principalmente de su vecindad y existen secuencias con un paso de tiempo regular.

A diferencia del experimento anterior, los datos no están en el formato del simulador. Cada sistema requiere un método de limpieza propio que lleve las imágenes a una evolución (T, n, n) de estados discretos con significado físico, con dos criterios comunes: los umbrales que definen los estados se calculan con toda la secuencia y no por imagen, para que un estado signifique lo mismo en todo momento; y la malla es la misma para todos los pasos de tiempo, para que el autómata no confunda un cambio de encuadre con una dinámica.

1.2.1. Propagación de un incendio (FLAME 3)

1.2.1.1. Datos de origen

Se utiliza el subconjunto *Nadir Thermal Plot* del conjunto de datos FLAME 3, que contiene secuencias térmicas tomadas por un dron (cámara Autel Robotics XT709) en vista nadir sobre una quema prescrita en Hanna Hammock el 28 de febrero de 2023. El escenario *plot 1* consta de 296 imágenes radiométricas en grados Celsius tomadas durante 25 minutos, con un intervalo mediano de 5 segundos entre imágenes.

Los archivos se proporcionan en dos formatos: imágenes JPG en pseudocolor y GeoTIFF radiométricos con la temperatura absoluta de cada píxel. Se descartan los JPG porque la cámara aplica un control automático de ganancia que estira la paleta entre la temperatura mínima y máxima de cada imagen, de modo que un mismo color no corresponde a la misma temperatura en imágenes distintas. Los GeoTIFF, en cambio, contienen temperaturas absolutas y están georreferenciados.

1.2.1.2. Limpieza

1. **Alineación.** Todos los GeoTIFF comparten la misma malla georreferenciada (EPSG:26916, 0.153×0.162 m por píxel), por lo que el movimiento del dron ya está corregido: el píxel (i, j) es el mismo punto del terreno en todas las imágenes.

2. **Recorte.** Las zonas que la cámara no observó quedan en 0 °C. Se calcula la máscara de píxeles con dato en todas las imágenes y se toma el rectángulo alineado a los ejes de mayor área dentro de ella: 416×552 píxeles, aproximadamente 67.5×84.3 m.

3. **Reducción a $n \times n$.** Cada imagen X_t se convoluciona con un kernel separable y se muestrea en una malla de $n \times n$ centros equiespaciados, $Y_t = K_r X_t K_c^\top$. Se usa un kernel gaussiano, que evita el *aliasing* sin oscilaciones; los tres kernels evaluados (caja, triangular y gaussiano) conservan la temperatura media y difieren en cuánto suavizan los picos (figura 1.22).

4. **Estados.** Se agrupan las temperaturas de todas las celdas de todas las imágenes con K-Means unidimensional, para que cada estado corresponda al mismo rango de temperatura en todo momento. El número de grupos k se elige con el método del codo sobre la inercia, usando el coeficiente de silueta como verificación (figura 1.23). Los umbrales entre estados son los puntos medios entre centroides consecutivos.

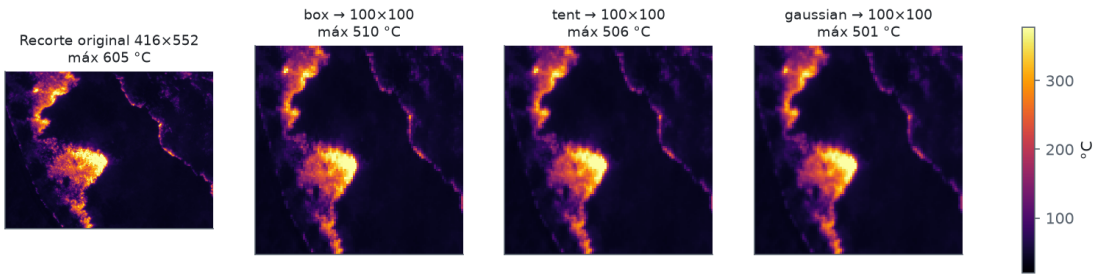


Figura 1.22: Comparación de kernels de reducción en la imagen con mayor temperatura de *plot 1*.

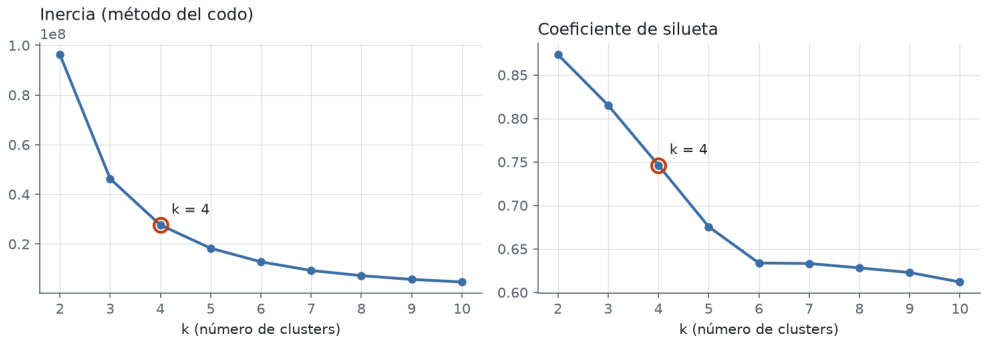


Figura 1.23: Inercia y coeficiente de silueta de K-Means para $k = 2, \ldots, 10$. El codo se encuentra en $k = 4$.

El resultado para *plot 1* con $n = 100$ es una evolución de $296 \times 100 \times 100$ con cuatro estados (tabla 1.13). La proporción de estados evoluciona de forma suave: el frente cruza el encuadre, la quema alcanza su máximo alrededor de $t \approx 200$–230 y después la zona se enfría (figuras 1.24 y 1.25).

Estado	**Centroide**	**Rango**	**Fracción**	**Interpretación**
0	35.8 °C	< 56 °C	83.7 %	Suelo o vegetación sin quemar o ya fría
1	76.1 °C	56–116 °C	11.4 %	Precalentamiento o rescoldo
2	156.7 °C	116–225 °C	3.6 %	Combustión latente
3	293.5 °C	≥ 225 °C	1.3 %	Frente de llama

Tabla 1.13: Estados obtenidos para *plot 1* de FLAME 3.

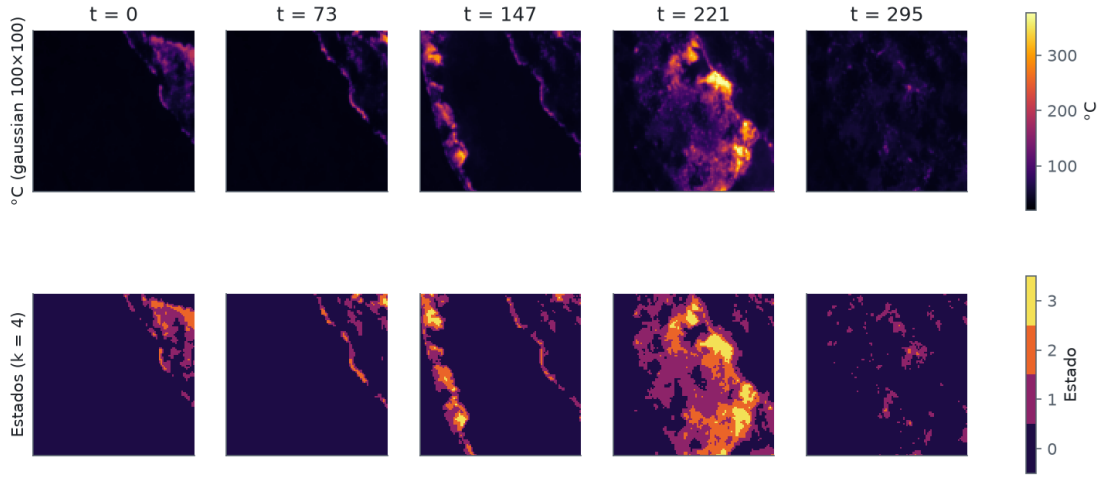


Figura 1.24: Temperatura reducida a 100×100 y estados en cinco momentos de *plot 1*.

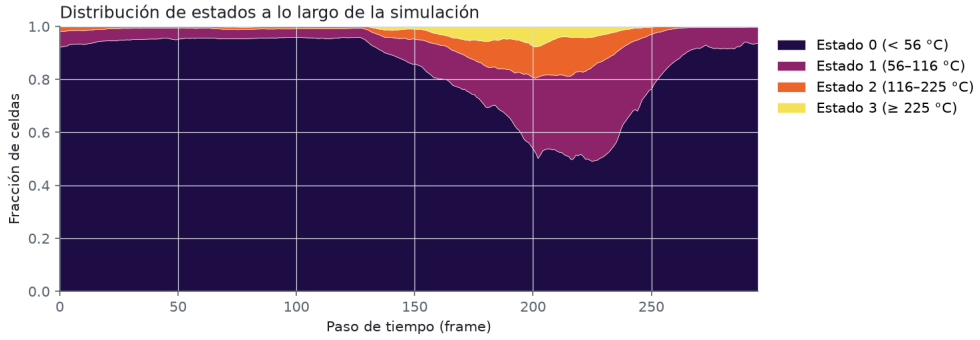


Figura 1.25: Fracción de cada estado a lo largo de la secuencia de *plot 1*.

1.2.1.3. Entrenamiento y resultados

TODO: Entrenar el autómata celular neuronal con la evolución de *plot 1* (4 estados, salida multiclase) y comparar la evolución generada contra la observada.

TODO: Procesar *plot 2* (los GeoTIFF en °C aún no se descargan; solo se cuenta con los JPG) y evaluar si la regla aprendida en *plot 1* generaliza.

1.2.2. Desarrollo embrionario

1.2.2.1. Datos de origen

Se utiliza un conjunto de datos público de imágenes *time-lapse* de embriones humanos en incubadora (Gomez et al., 2022), en el plano focal central. Contiene 704 embriones con una mediana de 548 imágenes cada uno (mínimo 137, máximo 1140), en escala de grises de 500×500 píxeles, desde el cigoto hasta mórula o blastocisto.

Cada imagen muestra el pozo de cultivo, la *zona pelúcida* (una capa que envuelve al embrión y se observa como un anillo gris con textura fina) y, dentro de ella, las células. El conjunto presenta tres particularidades que la limpieza debe resolver: 211 embriones repiten todas sus imágenes en una subcarpeta (se toma una sola copia), los números de imagen no tienen ceros a la izquierda (se ordenan numéricamente) y en algunas secuencias el embrión sale de cuadro al final.

1.2.2.2. Limpieza

1. **Localización de la zona pelúcida.** El círculo se calcula una sola vez por embrión, para que el ruido de la detección no aparezca como un cambio de escala entre imágenes. En una imagen aislada el borde de la zona es demasiado tenue para la transformada de Hough, pero la zona permanece fija mientras las células se mueven: la desviación estándar temporal de cada píxel dibuja el interior de la zona como un disco nítido (figura 1.26), al que se ajusta un círculo con RANSAC. El borde exterior se ubica donde termina la textura fina de la zona en la imagen media.

2. **Imágenes inválidas.** Se descartan las imágenes sin textura dentro del círculo (embrión fuera de cuadro) y se conserva el tramo continuo más largo de imágenes válidas.

3. **Recorte y reducción.** Se recorta el cuadrado del círculo exterior y se reduce a $n \times n$ por promedio de área, de modo que cada embrión queda normalizado al tamaño de su zona pelúcida.

4. **Estados.** Se definen cinco estados (tabla 1.14). Los dos primeros se obtienen por geometría; dentro de la zona, los bordes celulares se detectan con el operador de Sobel sobre la imagen reducida, con un umbral de Otsu calculado con todas las imágenes del embrión.

5. **Reducción de ruido.** Se aplica histéresis a los bordes (un borde débil se conserva solo si está conectado a uno fuerte) y una mediana temporal de tres imágenes. La apertura morfológica se descartó porque elimina las membranas, que miden una o dos celdas de grosor (figura 1.27).

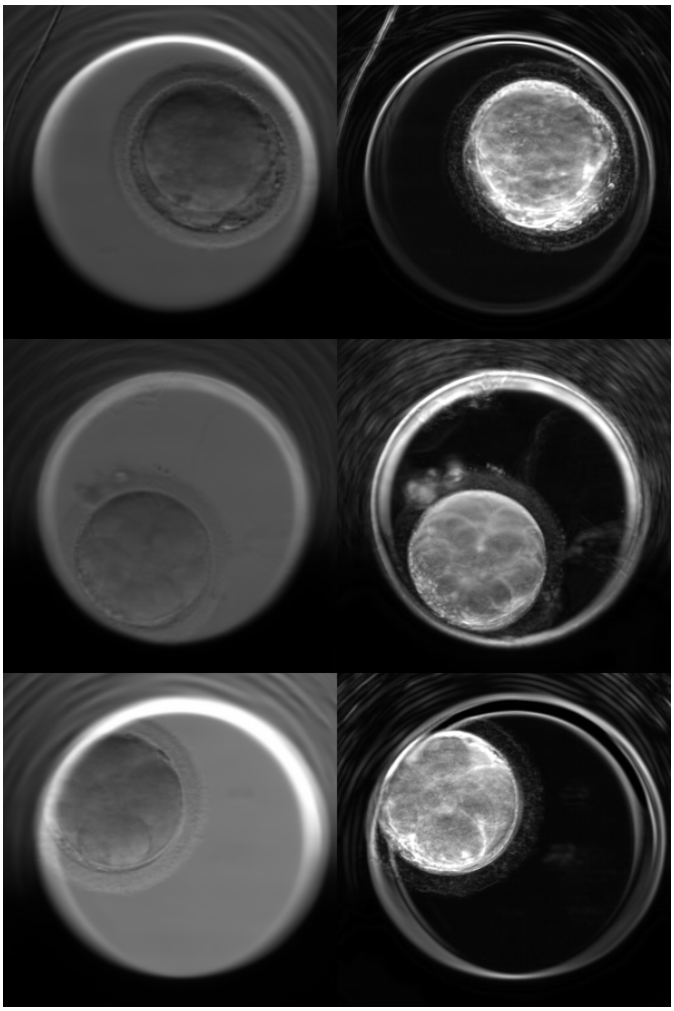


Figura 1.26: Media temporal (izquierda) y desviación estándar temporal (derecha) de tres embriones. El interior de la zona pelúcida aparece como un disco de alta variación.

Estado	Nombre	Regla
0	Fuera	Fuera del círculo exterior de la zona pelúcida.
1	Zona pelúcida	Anillo entre el círculo interior y el exterior.
2	Interior	Interior de la zona que no es borde ni brillo.
3	Borde	Gradiente de Sobel sobre el umbral de Otsu, con histéresis y mediana temporal.
4	Brillo	Intensidad mayor a la media más 1.5 desviaciones estándar del interior, en celdas que no son borde.

Tabla 1.14: Estados de la segmentación de embriones.

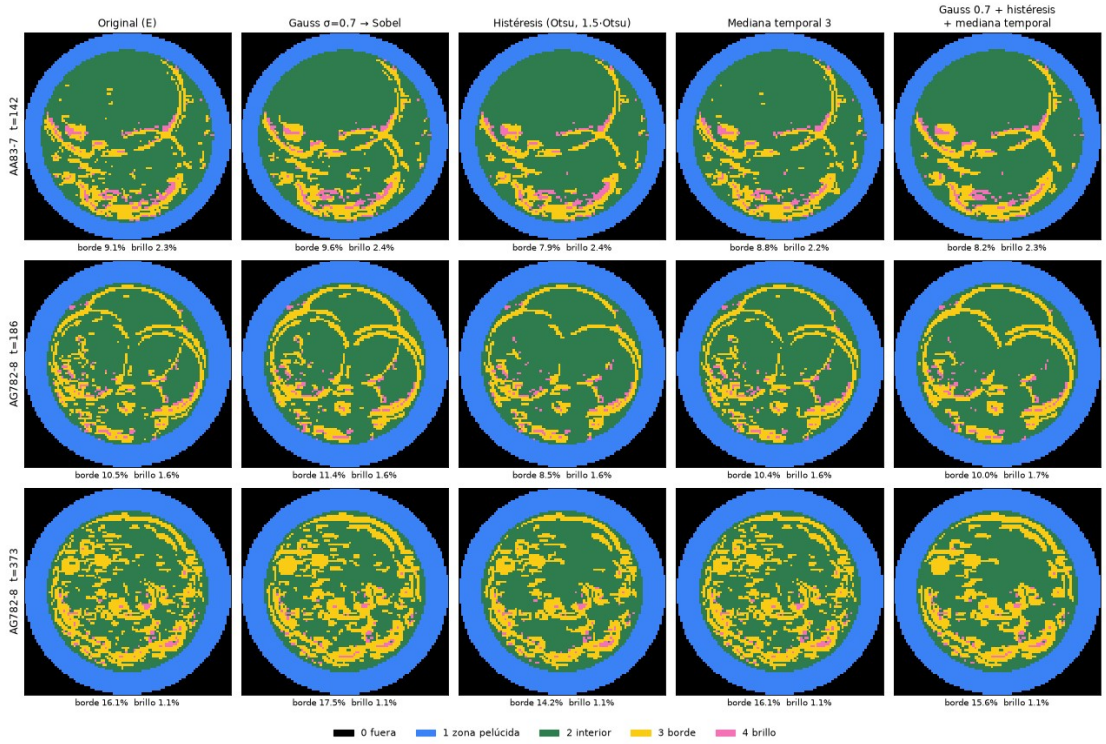


Figura 1.27: Alternativas de reducción de ruido sobre los bordes detectados.

La limpieza se aplicó a tres embriones. En el embrión AG782-8 se conservan 374 de 565 imágenes, desde el cigoto hasta mórula (figura 1.28); la fracción de borde dentro del embrión crece con el número de células, de 7.3 % al inicio a 25.5 % al final (figura 1.29).

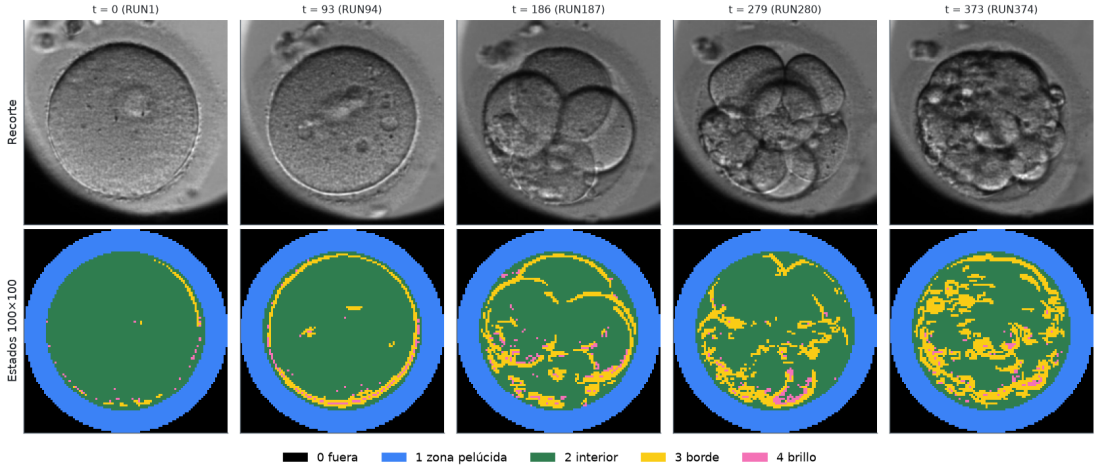


Figura 1.28: Recorte y estados en cinco momentos del embrión AG782-8.

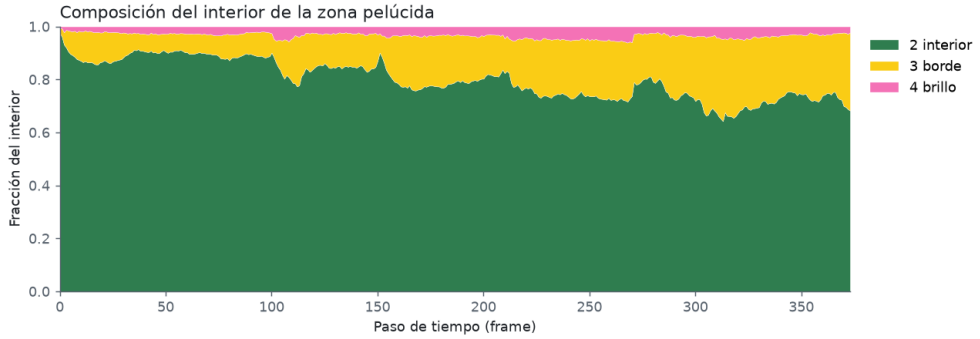


Figura 1.29: Composición del interior de la zona pelúcida del embrión AG782-8 a lo largo del tiempo.

1.2.2.3. Entrenamiento y resultados

TODO: Procesar los 704 embriones y descartar los que estén pegados a la pared del pozo, cuyo borde brillante aparece como una franja fija de estados 3 y 4.

TODO: Entrenar el autómata celular neuronal (5 estados, salida multiclase) y comparar la evolución generada contra la observada.

1.2.3. Seguimiento de células (Cell Tracking Challenge)

El *Cell Tracking Challenge* publica secuencias *time-lapse* bidimensionales de células en cultivo (migración, división y muerte celular) obtenidas con distintas técnicas de microscopía, junto con anotaciones de segmentación y seguimiento. A diferencia de los embriones, las anotaciones de segmentación ya identifican cada célula, por lo que la limpieza parte de máscaras y no de la imagen cruda.

Se consideran los ocho conjuntos de entrenamiento 2D de menor tamaño: DIC-C2DH-HeLa, Fluo-C2DL-Huh7, Fluo-C2DL-MSC, Fluo-N2DH-GOWT1, Fluo-N2DL-HeLa, PhC-C2DH-U373, PhC-C2DL-PSC y Fluo-N2DH-SIM+ (este último simulado, con segmentación perfecta).

TODO: Descargar los conjuntos (el servidor de datos no respondía el 7 de octubre de 2026) y elegir las secuencias con segmentación completa en todas las imágenes.

TODO: Definir los estados a partir de las máscaras de segmentación (por ejemplo, fondo, interior de célula y borde de célula) y escribir el método de limpieza.

TODO: Entrenar el autómata celular neuronal y comparar la evolución generada contra la observada.

1.3. Morfogénesis

En los experimentos anteriores se conoce la evolución completa y el autómata celular neuronal aprende la transición entre cada par de pasos consecutivos. En este experimento solo se conocen la condición inicial y la configuración final: el autómata debe encontrar una regla local que, aplicada durante cierto número de pasos, lleve de una a la otra.

TODO: Definir las configuraciones inicial y final a reproducir.

TODO: Agregar un modo de entrenamiento en el que la pérdida se calcule sobre la configuración obtenida después de N pasos y no sobre cada transición, ya que el *script* de entrenamiento actual usa pares de pasos consecutivos.

TODO: Entrenar, analizar la evolución intermedia que encuentra el autómata y su estabilidad después de alcanzar la configuración final.

Bibliografía