

Instituto Politécnico Nacional
Escuela Superior de Cómputo



Trabajo Terminal: 2026-A114

Simulación de sistemas complejos mediante autómatas celulares neuronales

---

Presenta:

Angeles Lopez Erick Jesse

eangelesl1700@alumno.ipn.mx

Director:

Dr. Genaro Juárez Martínez

Ciudad de México, 8 de octubre de 2026

Índice general

1. Experimentación y resultados **1**

1.1. Duplicación de reglas 2

1.1.1. El juego de la vida 2

1.1.1.1. Capacidad de replicación 4

1.1.1.2. Aprendizaje de reglas similiares 5

1.1.1.3. Efecto del tamaño de la vecindad 10

Referencias **17**

Capítulo 1

Experimentación y resultados

Una vez construido, validado e implementado el simulador, el siguiente paso es la experimentación con el objetivo de replicar el comportamiento de sistemas complejos.

A lo largo del siguiente capitulo se exponen tres experimentos realizados con el simulador para entrenar automatas celulares neuronales con un analisis paralelelo mediante Mathematica. Estos son los siguientes experimentos.

1. **Replicación de comportamientos conocidos**. Se entrena el autómata celular neuronal con evoluciones de reglas bien conocidas (juego de la vida, *sandpile* y hormiga de Langton) para medir su capacidad de recuperar la regla a partir de la evolución y la vecindad.

2. **Replicación de sistemas complejos naturales**. Se entrena con evoluciones obtenidas de sistemas reales sin una regla de transición conocida: la propagación de un incendio,

   TODO: Definir un segundo experimento

   y el movimiento de células en cultivo. Cada sistema requiere su propio método de limpieza para llevar los datos al formato (T, n, n) del simulador.

3. **Morfogénesis**. Se conoce la condición inicial y la configuración final, pero no la evolución intermedia; el autómata debe encontrar una regla que lleve de una a otra.

1.1. Duplicación de reglas

EL objetivo de esta primera serie de experimentos es replicar el comportamiento de evoluciones conocidas para identificar las capacidades y limitaciones del automata celular neuronal en entornos controlados.

Primero se realizan experimentos sobre el juego de la vida de John Conway. Se usa como base la regla B3/S23, se caracteriza la regla y posteriormente se definen los metaparametros y las condiciones necesarias para que el automata celular neuronal pueda replicar (o intentar replicar) el comportamiento de dicha regla.

Posteriormente se experimenta sobre *sandpile*: Un sistema autorganizado que consiste de una cuadricula y un generador de arena que cuando se llena dispersa la arena en sus vecinos cercanos.

Finalmente, se replica la hormiga de Langton mediante un automata celular. La hormiga de Langton es un agente reactivo en un espacio bidimensional que sigue una serie instrucciones según su posición. Tambien conocido como *turmite* por ser una maquina de Turing en un espacio bidimensional.

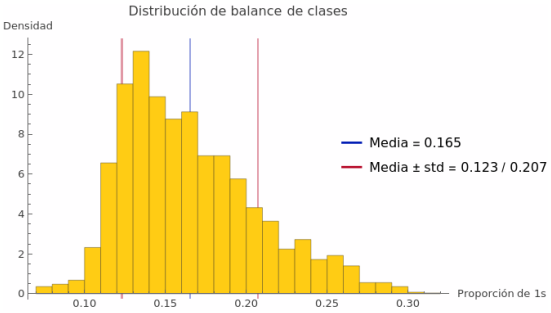
1.1.1. El juego de la vida

Para este experimento, se utiliza principalmente la regla B3/S23, de la cual fueron evolucionadas 100 condiciones iniciales aleatorias en un espacio de 100×100 durante 100 pasos evolutivos para analizar su comportamiento.

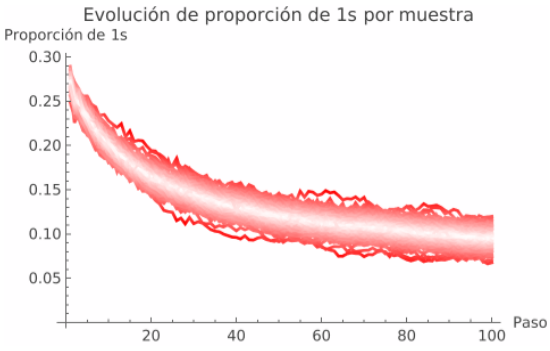
De acuerdo con la figura 1.1a, la regla B3/S23 produce el estado uno un 16.5 % de las veces. La mayoria de los datos se agrupa entre 12.3 % y 20.7 %, donde los porcentajes mas grandes corresponden a las configuraciones iniciales aleatorias. Esto se demuestra en la figura 1.1b donde la proporción del estado uno de todas las evoluciones a través del tiempo decrece hasta estabilizarse, comportamiento característico del atractor de dicha regla.

Por otro lado, dado que la salida de cada paso evolutivo es la entrada del siguiente, también se analiza el desbalanceo de entradas, es decir, la frecuencia con la que aparecen diferentes patrones. Para esto, utilizaremos la nomenclatura $CxNy$ que cuenta el número de unos que aparecen en el centro (C) y en el exterior (N).

En la figura 1.2 se muestran las frecuencias de aparición de todos los patrones



(a) Histograma de distribución de la clase 1. Media de 16.5 y desviación estándar de 4.2.



(b) Proporción de unos a lo largo del tiempo de todas las muestras.

Figura 1.1: Resultados estadísticos del conjunto de pruebas para la regla B3/S23.

en el mismo conjunto de datos. La regla B3/S23 no genera mucha vida dentro de las comunidades, lo que causa un desbalanceo de entradas. Los patrones con menor frecuencia de aparición son $C1N8$ y $C0N8$ sumando menos del 0.02 %, lo que causa un problema de representación o sesgo de muestra.

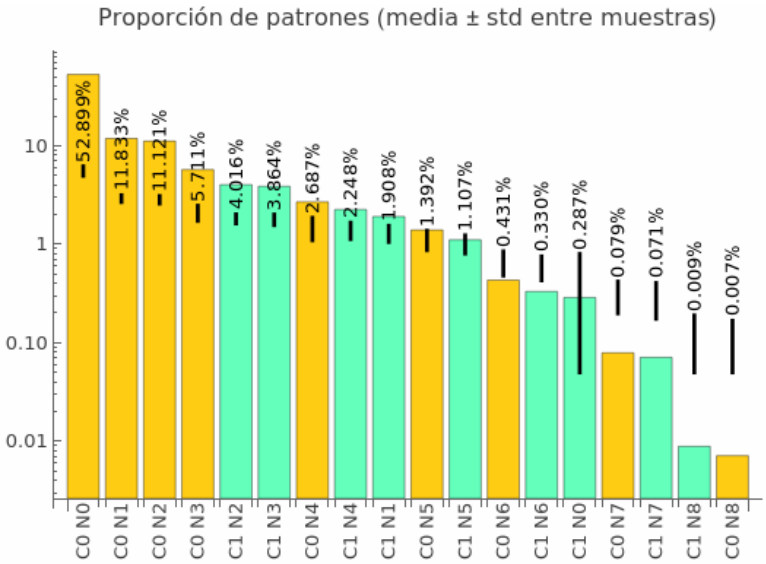


Figura 1.2: Distribuciones de probabilidad de los patrones en la regla B3/S23.

Para evitar este sesgo, se proponen dos soluciones: (1) realizar un sobremuestreo de los datos menos frecuentes o (2) modificar la función de costo para penalizar en mayor medida los errores en patrones poco representados. Las pruebas a continuación se realiza con una perdida objetivo exigente con la intención de encontrar

configuraciones capaces de replicar el comportamiento de forma exacta.

1.1.1.1. Capacidad de replicación

Se usa la siguiente nomenclatura:

numero de capas : numero de neuronas : función de activación

para especificar la composición de la red neuronal.

Fueron probadas 10 combinaciones de funciones de activación, de las cuales una sola converge en menos de 1000 épocas. En la tabla 1.1 se obervan los resultados. La falta de convergencia puede deberse al tamaño de la red neuronal o la pérdida objetivo utilizada.

Capa Oculta	**Capa Salida**	**Épocas**	**Pérdida**	**Tiempo**
1:4:ReLU	2:Linear	122	0.000098	4.64 s
1:4:TanH	1:Sigmoid	1000	0.052895	40.19 s
1:4:TanH	2:Linear	1000	0.079425	36.52 s
1:4:Sigmoid	2:Linear	1000	0.159343	36.71 s
1:4:Sigmoid	1:Sigmoid	1000	0.159343	39.37 s
1:4:ReLU	2:TanH	1000	0.179589	38.65 s
1:4:ReLU	1:Sigmoid	1000	0.269196	38.16 s
1:4:Linear	1:Sigmoid	1000	0.297529	39.12 s
1:4:Linear	2:Linear	1000	0.297529	34.75 s
1:4:ReLU	2:Sigmoid	1000	0.374756	37.55 s

Tabla 1.1: Comparativa de rendimiento con múltiples hiperparámetros de la regla B3/S23: Pérdida objetivo 0.0001, límite de épocas: 1000, tamaño del lote: 8192, tasa de aprendizaje: 0.001, semilla aleatoria: 42.

Al incrementar el numero de capas ocultas y de neuronas, se observa en la tabla 1.2 que existen cuatro nuevas configuraciones que alcanzan la convergencia. Adicionalmente, en la figura 1.3 observamos que el estancamiento ocurre en las primeras 12 épocas, lo que sugiere una limitación de la tasa de aprendizaje.

Capa Oculta	Capa Salida	Épocas	Pérdida
4:8:ReLU	2:Linear	18	0.000087
4:8:TanH	1:Sigmoid	51	0.000097
4:8:TanH	2:Linear	35	0.000097
4:8:Sigmoid	2:Linear	79	0.000095
4:8:Sigmoid	1:Sigmoid	1000	0.159342
4:8:ReLU	2:TanH	1000	0.126928
4:8:ReLU	1:Sigmoid	133	0.000096
4:8:Linear	1:Sigmoid	1000	0.297542
4:8:Linear	2:Linear	1000	0.297544
4:8:ReLU	2:Sigmoid	1000	0.374756

Tabla 1.2: Comparativa de rendimiento con múltiples hiperparámetros de la regla B3/S23: Pérdida objetivo 0.0001, límite de épocas: 1000, tamaño del lote: 8192, tasa de aprendizaje: 0.001, semilla aleatoria: 42.

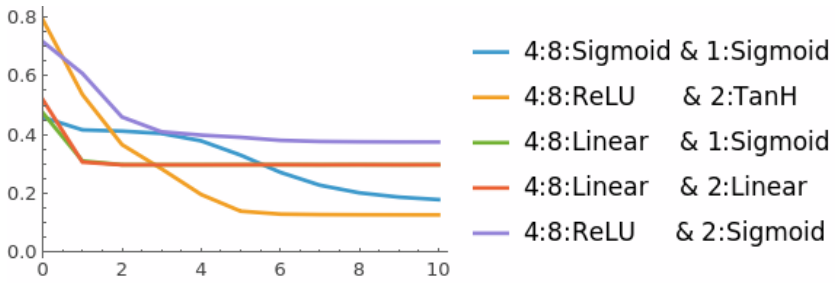


Figura 1.3: Registro de pérdida obtenida en los primeros 12 pasos de las configuraciones sin convergencia de la tabla 1.2.

Queda demostrado que que un automata celular neuronal puede aprender el comprotamiento de una regla ya conocida con un error de 0.0001. Para fines de esta investigación, se omiten las configuraciones no convergentes.

1.1.1.2. Aprendizaje de reglas similiares

De acuerdo con la figura 1.2, la probabilidad de aparición de los patrones $C0N8$ y $C1N8$ son menores que 0.02 %. La siguiente prueba busca identificar la relación entre la perdida objetivo y la regla aprendida. Para esto, se entrena la regla B3/S23 con diferentes perdidas objetivo y se identifica como esos patrones infrecuentes afectan el aprendizaje.

Cabe mencionar que aunque las reglas del juego de la vida son semitotalísticas, existe la posibilidad de que la regla aprendida no lo sea, es decir, el autómata celular neuronal si haga distinción entre dos patrones que conduzcan el mismo comportamiento. Por ejemplo, podemos generar de ocho formas diferentes el patrón $C0N1$:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \cdots = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

pero a falta de exposición de todas las posibles configuraciones, la red neuronal puede distinguir patrones, convirtiendo a la regla en una tradicional.

Como se mencionó en el capítulo **??**, las reglas tradicionales y las semitotalísticas son subconjuntos mutuos. Para verificar que la regla aprendida coincida con todas las posibles configuraciones de los patrones, se diseñó la configuración inicial de la figura 1.4, la cual se evoluciona un paso y se comparan los centros de cada subespacio de 3×3.

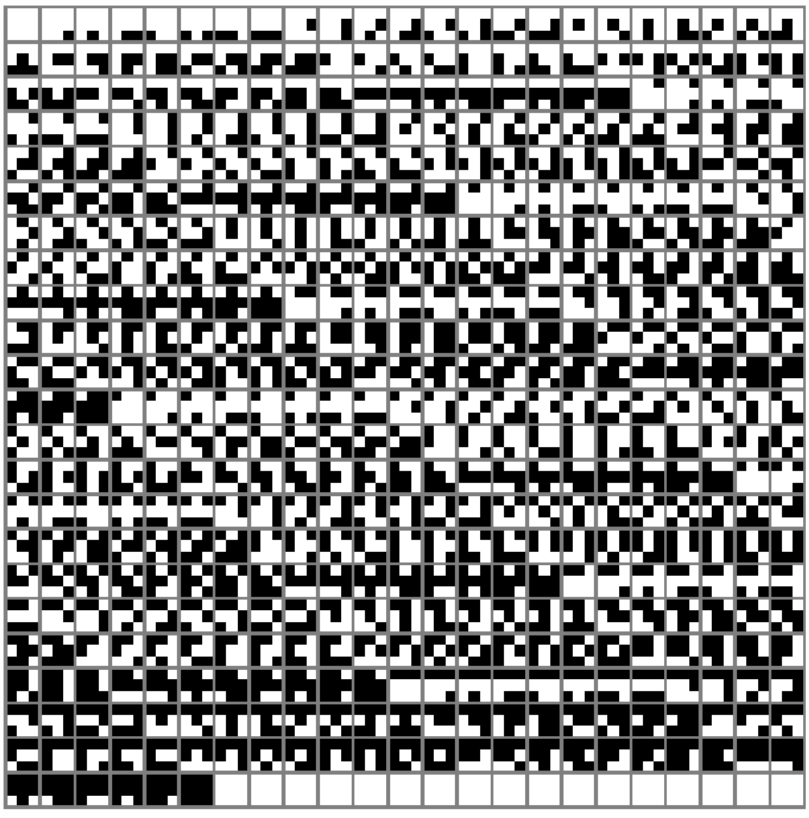


Figura 1.4: Espacio que contiene todas las permutaciones posibles de 2 estados en 9 células.

Los autómatas celulares neuronales que utilizaron la pérdida objetivo de 0.2 y 0.3 aprendieron la regla 0, es decir, todas las configuraciones evolucionan a 0 (ver figura 1.5).

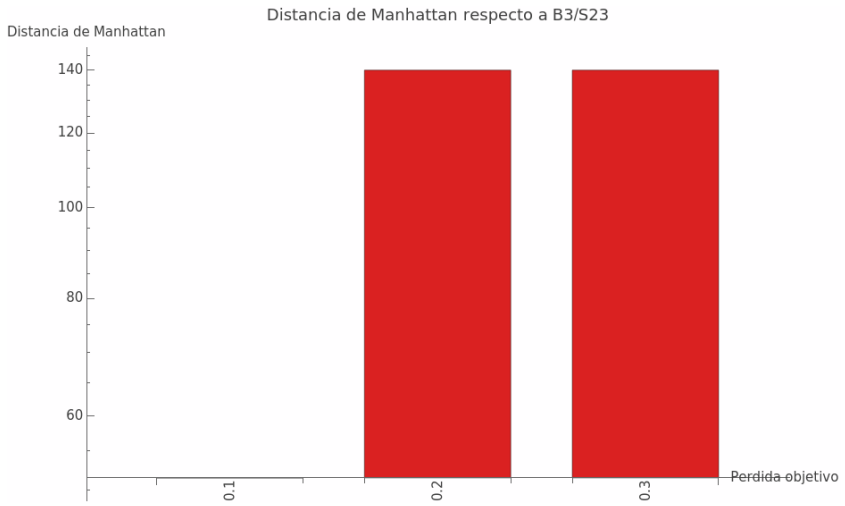


Figura 1.5: Distancia Manhattan de los vectores de regla de múltiples perdidas objetivo comparadas con B3/S23.

Podemos concluir que esta configuración es estable porque, aunque existan patrones de baja frecuencia como $C0N8$ y $C1N8$, sigue siendo capaz de replicar el comportamiento con una pérdida objetivo de 0.1. Una hipótesis es que la red neuronal se inicializa para generar ceros, al no recibir nunca esas entradas, siempre se mantienen en ese valor.

A continuación, se replica el experimento para las siguientes reglas *life-like*: B3/S238, B38/S238 y B3/S236.

La regla B3/S238 (Figura 1.6) aprende una regla que difiere únicamente en un elemento (con una perdida objetivo entre 0.03 y 0.1). Esta diferencia corresponde al patrón $C1N8$ el cual solo tiene una posible representación:

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

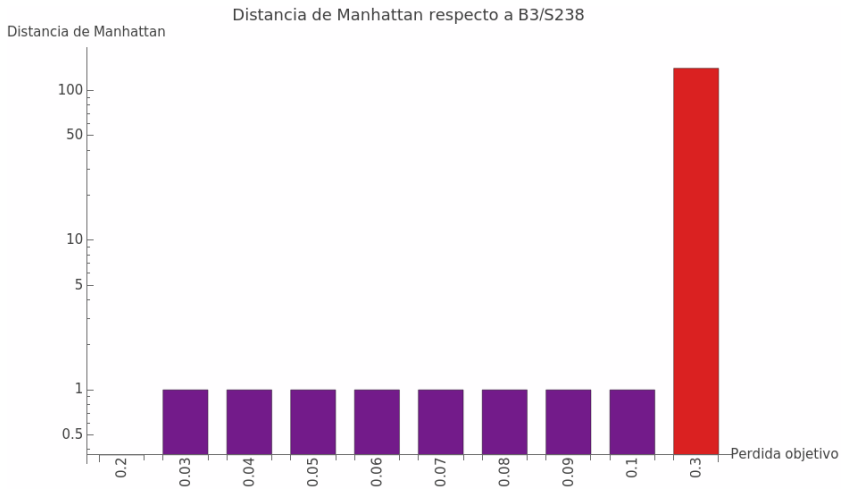


Figura 1.6: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B3/S238.

Por lo tanto, la regla aprendida considera todas las permutaciones del patrón $C1N8$, es decir, aprende una regla semitotalistica que ignora supervivencia con 8 vecinos. Su regla aprendida equivale a B3/S23. Esto lo corroboramos con la figura 1.7, en donde se muestra la única diferencia entre ambas reglas y cómo fue omitida durante el entrenamiento.



Figura 1.7: Últimos 50 elementos de los vectores de regla de B3/S238, B3/S23 y los aprendidos por el autómata celular neuronal.

La regla B38/S238 (Figura 1.8) aprende 2 comportamientos diferentes: B3/S238 y B3/S23, como se observa en la figura 1.9.

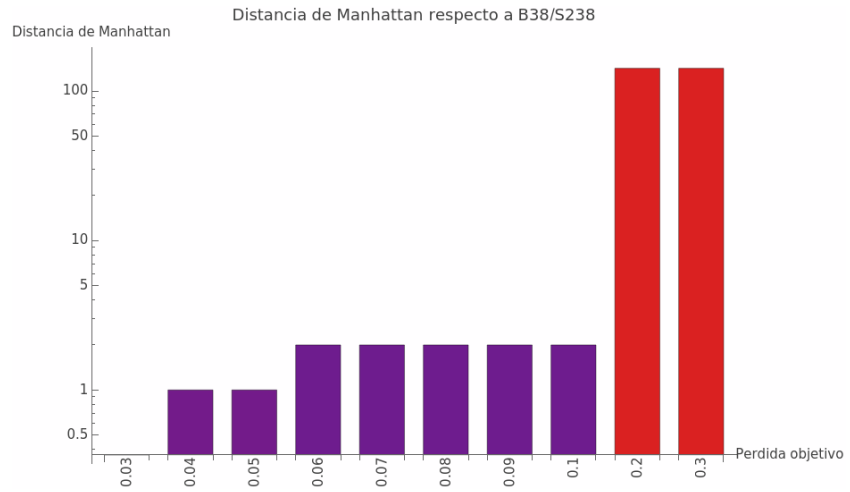


Figura 1.8: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B38/S238.



Figura 1.9: Últimos 50 elementos de los vectores de regla de B38/S238, B3/S23, B3/S238 y los aprendidos por el autómata celular neuronal.

En la regla B3/S236 (Figura 1.10) con 0.2 difieren 32 elementos, de los cuales 28 sustituyeron el 1 por 0 (figura 1.11a) y 4 al revez (figura 1.11b). El primer conjunto corresponde al patrón $C1N6$, mientras que los 4 restantes necesitan otros 4 patrones adicionales para capturar a $C1N7$. Por esta razón, la regla aprendida no es semitotalística, porque hace distinción entre elementos de su vecindad.

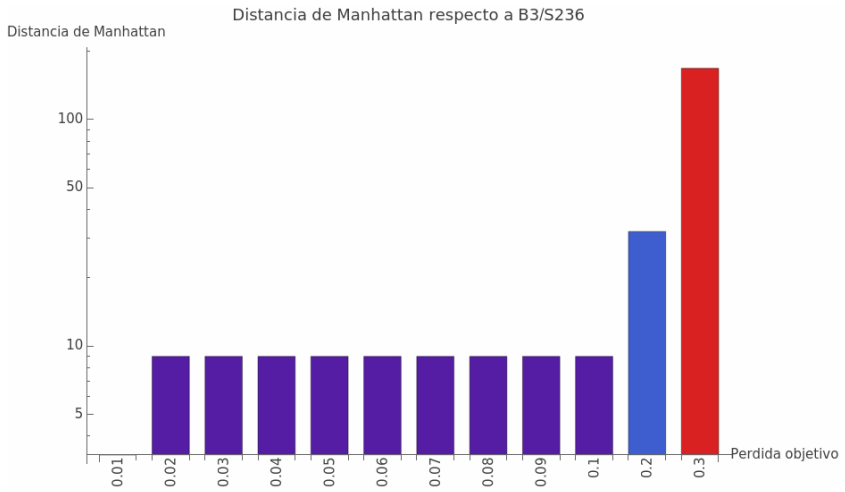
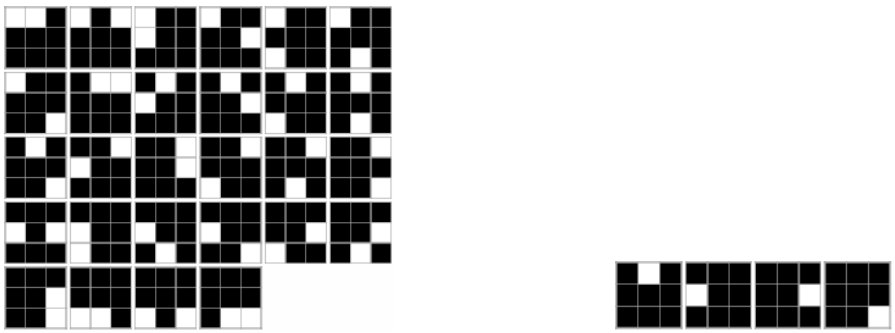


Figura 1.10: Distancia Manhattan de los vectores de regla de múltiples pérdidas objetivo comparadas con B3/S236.



(a) Se intercambió 1 por 0 en $C1N6$

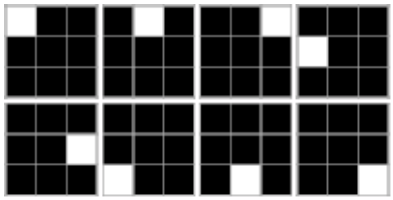
(b) Se intercambió 0 por 1.

Figura 1.11: Patrones que difieren entre B3/S236 y el autómata celular neuronal con una pérdida objetivo de 0.2.

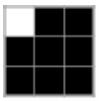
El resto de reglas aprendidas erróneamente diferencian los patrones de las figuras 1.12a y 1.12b. Ambos patrones se encuentran completos ($C1N7$ y $C1N8$), por lo que sobrevive con 7 y 8 vecinos, es decir, aprendio la regla B3/S23678.

1.1.1.3. Efecto del tamaño de la vecindad

Experimentar con reglas ya conocidas implica conocer toda la configuración necesaria de ese sistema en especifico. Esto no ocurre en fenomenos reales donde no conocemos el numero de estados, la función de traansición o, especificamente para



(a) Se intercambió 0 por 1 en $C1N7$



(b) Se intercambió 0 por 1 en $C1N8$

Figura 1.12: Patrones que difieren entre B3/S236 y el autómata celular neuronal con una pérdida objetivo de 0.1.

este experimento, la vecindad que define el sistema. Los siguientes experimentos tienen el proposito de identificar como afecta el desconocimiento de la vecindad en un sistema complejo al momento de intentar replicar el comportamiento de la regla B3/S23.

Dada la vecindad de la regla, definimos las siguientes pruebas: (1) eliminación de una célula exterior, (2) eliminación de la célula central, (3) incremento del tamaño de la vecindad y (4) sustitución de elementos de la vecindad. Con esto se busca identificar un método de selección de vecindad que nos permita extraer el comportamiento esencial de un sistema complejo.

La vecindad semitotalística se divide en dos subvecindades, el centro y los bordes. Dado que el valor de la subvecindad de los bordes esta dado por la sumatoria, cada uno de ellos tiene la misma relevancia, por lo que solo es necesario realizar pruebas ignorando uno de esos elementos. La tabla 1.3 muestra las perdidas objetivos obtenidas bajo diferentes configuraciones, todas con una pérdida final mayor 0.1.

Tasa	Lote	ReLU 2:Linear	TanH 1:Sigmoid	TanH 2:Linear	ReLU 1:Sigmoid	Segundos
0.0003	1024	0.121595	0.121808	0.121824	0.121536	216
0.0003	4096	0.121675	0.122049	0.122123	0.121576	58
0.0003	8192	0.121774	0.122444	0.122367	0.121747	40
0.001	1024	0.121590	0.121645	0.121871	0.121605	213
0.001	4096	0.121546	0.121790	0.121768	0.121580	58
0.001	8192	0.121794	0.121946	0.122043	0.121604	42
0.003	1024	0.121685	0.414336	0.414441	0.486924	210
0.003	4096	0.121647	0.230796	0.318269	0.121626	58
0.003	8192	0.192933	0.122014	0.122387	0.121660	35

Tabla 1.3: Perdida final de cada configuración. Vecindad de 3×3 sin el vecino noroeste, 100 épcas, semilla 42, red de tamaño 16:16. Pérdida mínima alcanzable: 0.121576.

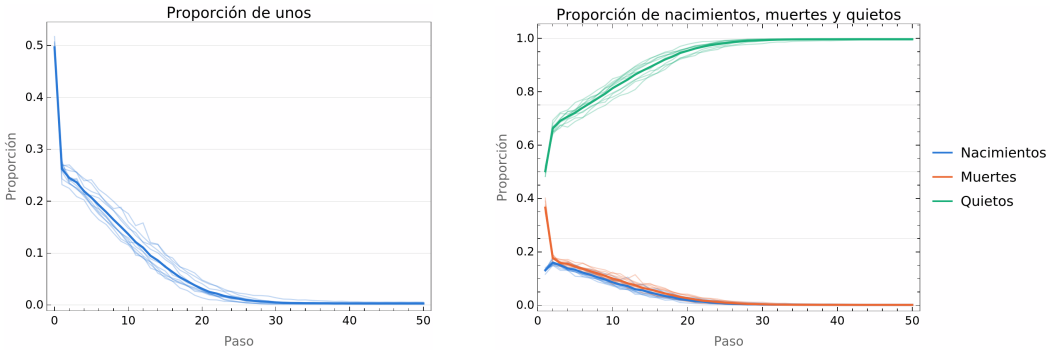
Como se menciono anteriormente, una perdida objetivo de 0.1 es lo suficientemente alta como para que la red neuronal no haya podido replicar el comportamiento. Sin embargo, la mejor configuración (16:16:reLU & 1:Sigmoid) difiere en 98 de 512 elementos (19 %). La regla aprendida no genera osciladores, sino unicamente produce naturaleza muerta.

Si ignoramos la célula central (Tabla 1.4) observamos que ninguna de las configuraciones tuvo una perdida menor al 0.07, mucho menor que eliminando un vecino del exterior. Es una bella casualidad como mediante este experimento, se demuestra una vez que existe una mayor dependencia de los estados vecinos que del propio. La regla aprendida tiende a eliminar todos los estados 1 y genera pocas configuraciones estáticas y cíclicas en menos de 50 pasos, tal como se muestran en las figuras 1.13.

Capa Oculta	**Capa Salida**	**Pérdida**
1:4:ReLU	2:Linear	0.088437
2:8:ReLU	2:Linear	0.085921
4:8:ReLU	2:Linear	0.078934
4:16:ReLU	2:Linear	0.078685
8:16:ReLU	2:Linear	0.078674
4:16:ReLU	2:Linear	0.078685
8:16:ReLU	2:Linear	0.078674
1:4:TanH	1:Sigmoid	0.081676
2:8:TanH	1:Sigmoid	0.078866
4:8:TanH	1:Sigmoid	0.078713
4:16:TanH	1:Sigmoid	0.078670
8:16:TanH	1:Sigmoid	0.078671
1:4:TanH	2:Linear	0.082283
2:8:TanH	2:Linear	0.078758
4:8:TanH	2:Linear	0.078716
4:16:TanH	2:Linear	0.078685
8:16:TanH	2:Linear	0.078680
1:4:ReLU	1:Sigmoid	0.168493
2:8:ReLU	1:Sigmoid	0.080522
4:8:ReLU	1:Sigmoid	0.078796
4:16:ReLU	1:Sigmoid	0.078688
8:16:ReLU	1:Sigmoid	0.078679

Tabla 1.4: Regla B3/S23 sin la célula central. Pérdida objetivo 0.0001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. Pérdida mínima alcanzable: 0.078650.

Por otro lado, el incremento de la vecindad no afecta el replicamiento del comportamiento. La red neuronal puede aprender la regla incluso con exceso de información. En la tabla 1.5 se muestran los mejores resultados con sus respectivas perdidas objetivos alcanzadas, todas superando el umbral establecido en el numero de epocas.



(a) Proporción de unos en cada paso evolutivo.

(b) Porcentaje nacimientos, muertes y células sin cambios en cada paso evolutivo.

Figura 1.13: Proporciones de estados y cambios de estados en 10 evoluciones con condiciones iniciales aleatorias durante 50 pasos con el autómata celular neuronal obtenido por 16:16:ReLU & 1:Sigmoid.

Vecindad	**Capa Oculta**	**Capa Salida**	**Pérdida**
5×5	4:16:ReLU	2:Linear	0.000035
	8:16:ReLU	2:Linear	0.000062
	16:16:ReLU	1:Sigmoid	0.000225
7×7	8:16:ReLU	2:Linear	0.000023
	8:16:ReLU	1:Sigmoid	0.000045
	4:16:ReLU	1:Sigmoid	0.000137
8×8	8:16:ReLU	2:Linear	0.000063
	8:16:ReLU	1:Sigmoid	0.000141
	16:16:ReLU	1:Sigmoid	0.000156

Tabla 1.5: Las tres configuraciones con menor pérdida de la regla B3/S23 al aumentar la vecindad. Pérdida objetivo 0.001, límite de é 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42. La vecindad de 8×8 abarca los desplazamientos -4 a 3 en cada eje.

Para finalizar, se realiza la sustitución, es decir, se elimina un elemento de la vecindad pero se compensa con un incremento de vecinos circundantes en ese punto faltante. Esto con el objetivo de analizar si la información adicional es útil o es unicamente ruido.

En la ta tabla 1.6 se experimenta con una vecindad de 9×9 ignorando dos vecinos diferentes. Se aprecia que el incremento de la vecindad reduce parcialmente la pérdida. Para el centro, pasamos de un 0.078650 a un 0.097587, y para el borde

de 0.121294 a 0.065987.

Vecindad	**Capa Oculta**	**Capa Salida**	**Pérdida**
7×7 sin $(-1, -1)$	16:16:ReLU	2:Linear	0.099847
	16:16:TanH	1:Sigmoid	0.098628
	16:16:TanH	2:Linear	0.098407
	16:16:ReLU	1:Sigmoid	0.099326
9×9 sin $(-1, -1)$	16:16:ReLU	2:Linear	0.098381
	16:16:TanH	1:Sigmoid	0.097587
	16:16:TanH	2:Linear	0.098029
	16:16:ReLU	1:Sigmoid	0.098368
7×7 sin $(0, 0)$	16:16:ReLU	2:Linear	0.067663
	16:16:TanH	1:Sigmoid	0.066962
	16:16:TanH	2:Linear	0.066976
	16:16:ReLU	1:Sigmoid	0.068002
9×9 sin $(0, 0)$	16:16:ReLU	2:Linear	0.067066
	16:16:TanH	1:Sigmoid	0.066031
	16:16:TanH	2:Linear	0.065987
	16:16:ReLU	1:Sigmoid	0.067197

Tabla 1.6: Regla B3/S23 con vecindades de 7×7 y 9×9 sin un vecino. Pérdida objetivo 0.001, límite de épocas: 500, tamaño del lote: 4096, tasa de aprendizaje: 0.001, semilla aleatoria: 42.

Con estos resultados experimentales, establecemos algunas consideraciones esenciales para el entrenamiento de autómatas celulares neuronales:

- La capacidad de generalización depende de clases y entradas balanceadas. Establecer una pérdida objetivo restrictiva fuerza a la red a ajustar sus pesos en regiones con patrones menos representados. El caso contrario atenúa estados y los conduce a otros comportamientos.
- El entrenamiento de reglas semitotalísticas no garantiza que la regla aprendida igual lo sea.
- Incrementar el tamaño de la vecindad es un costo computacional viable cuando se desconoce el tamaño de la vecindad real. El incremento de igual manera puede ayudar a disminuir la pérdida si es que aun existen vecinos que no fueron considerado pero con un limite contextual.

Estos experimentos confirman que no se requieren arquitecturas neuronales complejas para replicar este tipo de dinámicas evolutivas. Asimismo, queda valida-

da la metodología propuesta para extraer e identificar el vector de regla aprendido por el modelo, sentando las bases para los siguientes experimentos del capítulo.

Bibliografía